Contents

Tecnologias de Reforço da Privacidade 2

Anonimização de Datasets - com Privacidade, Utilidade e Análise de Risco 2

1. Seleção, Importação e Objetivo do Dataset 2

1.1 Dataset Escolhido 2

1.1.1 Distribuição do Dataset 3

1.1.2 Sanitização 3

1.2 Objetivo de Divulgação do Dataset 4

1.3 Requisitos de Privacidade 4

2. Caracterização do Dataset e Coding Models 5

2.1 Caracterização de Atributos 5

2.2 Riscos de Privacidade do Dataset Original 8

2.3 Distribuição de Atributos 9

2.4 Criação de Hierarquias 10

2.5 Peso de Atributos 12

3. Modelos de Privacidade: Utilidade, Privacidade e Avaliação de Risco 12

3.1 k-Anonymity e ℓ-Diversity 12

3.2 k-Anonymity e t-Closeness 16

3.3 Comparação dos Modelos 18

3.4 Recomendação Final 19

4. Anexos 20

4.1 Distribuição do Dataset 20

4.2 Qualidade e Conformidade dos Dados 21

4.3 Estatística-Alvo (CreditScore médio por faixa etária) 21

Tecnologias de Reforço da Privacidade

Anonimização de Datasets - com Privacidade, Utilidade e Análise de Risco

João Filipe - up202408782

[Nome 2] - up[número]

Abril 2025

---

1. Seleção, Importação e Objetivo do Dataset

1.1 Dataset Escolhido

Para a realização deste projeto, foi selecionado o dataset *Predicting Churn for Bank Customers*, disponível publicamente no Kaggle. Este dataset contém dados pessoais e financeiros de clientes bancários, o que o torna particularmente adequado para a aplicação de técnicas de anonimização, dada a natureza sensível das informações presentes.

O dataset possui as seguintes características:

- **Número de registos:** 10.000 clientes
- **Número de atributos:** 14

Os atributos são os seguintes:

Atributo	**Descrição**	**Tipo**
RowNumber	Número sequencial da linha	Inteiro
CustomerId	Identificador único do cliente	Inteiro
Surname	Apelido do cliente	Texto
CreditScore	Pontuação financeira do cliente (350–850)	Inteiro
Geography	País de origem (France, Spain, Germany)	Categórico
Gender	Género (Male, Female)	Categórico

Atributo	Descrição	Tipo
Age	Idade do cliente (18–92 anos)	Inteiro
Tenure	Tempo de ligação ao banco, em anos (0–10)	Inteiro
Balance	Saldo bancário do cliente (€)	Decimal
NumOfProducts	Número de produtos bancários (1–4)	Inteiro
HasCrCard	Possui cartão de crédito (0/1)	Binário
IsActiveMember	Membro ativo (0/1)	Binário
EstimatedSalary	Salário anual estimado (€)	Decimal
Exited	Abandonou o banco (0/1)	Binário

1.1.1 Distribuição do Dataset

A análise exploratória da distribuição dos atributos foi realizada em Python (ver os Anexos) e revelou os seguintes padrões:

- **CreditScore:** distribuição aproximadamente normal, com valores entre 350 e 850 e média de 650.5.
- **Geography:** a maioria dos clientes reside em França (5014), seguida da Alemanha (2509) e Espanha (2477).
- **Gender:** distribuição relativamente equilibrada - 5457 homens e 4543 mulheres.
- **Age:** distribuição assimétrica, concentrada entre os 25 e 50 anos, com média de 38.9 anos.
- **Tenure:** distribuição aproximadamente uniforme entre 0 e 10 anos.
- **Balance:** um número significativo de clientes apresenta saldo nulo; os restantes distribuem-se de forma contínua.
- **NumOfProducts:** a maioria possui 1 ou 2 produtos; valores de 3 ou 4 são pouco frequentes.
- **EstimatedSalary:** distribuição uniforme, indicando ampla diversidade salarial.

1.1.2 Sanitização

A análise de qualidade e conformidade dos dados confirmou que:

- Não existem valores nulos nem em falta em nenhum atributo.
- Todos os valores estão em conformidade com os formatos esperados (tipos, intervalos, categorias válidas).
- Não existem registos duplicados - cada cliente aparece exatamente uma vez.

O dataset está, portanto, pronto para importação direta no ARX, sem necessidade de sanitização adicional.

1.2 Objetivo de Divulgação do Dataset

O objetivo definido para a divulgação do dataset anonimizado é permitir a **análise da relação entre a faixa etária dos clientes e o seu CreditScore médio**, sem comprometer a privacidade individual.

Na prática, pretende-se que o dataset anonimizado permita a um departamento de risco bancário estudar como a idade influencia a pontuação financeira dos clientes, de forma a otimizar estratégias de segmentação e avaliação de risco - garantindo que um possível atacante não consiga reidentificar indivíduos específicos.

A análise estatística inicial (antes da anonimização) produziu os seguintes resultados:

Faixa Etária	CreditScore Médio	N.º Clientes
[18, 25[	653.97	457
[25, 35[	651.33	3222
[35, 45[	650.87	3981
[45, 55[	645.79	1458
[55, 93[	652.11	882

Tabela 1: CreditScore médio por faixa etária (dataset original).

Observa-se que o CreditScore médio é relativamente estável entre faixas etárias, com uma ligeira descida na faixa [45, 55[. Esta será a estatística de referência para avaliar a preservação de utilidade após anonimização.

1.3 Requisitos de Privacidade

1.3.1 Limite de Supressão

Será aplicado um limite de supressão de aproximadamente **3%** dos registos. Este valor equilibra a proteção da privacidade com a preservação da utilidade, sendo a supressão utilizada para eliminar outliers ou combinações de atributos raras que possam expor indivíduos.

1.3.2 Coding Model

Dá-se preferência à **generalização**, por preservar melhor a utilidade dos dados, recorrendo à supressão apenas quando a generalização não é suficiente para atingir os requisitos de privacidade definidos.

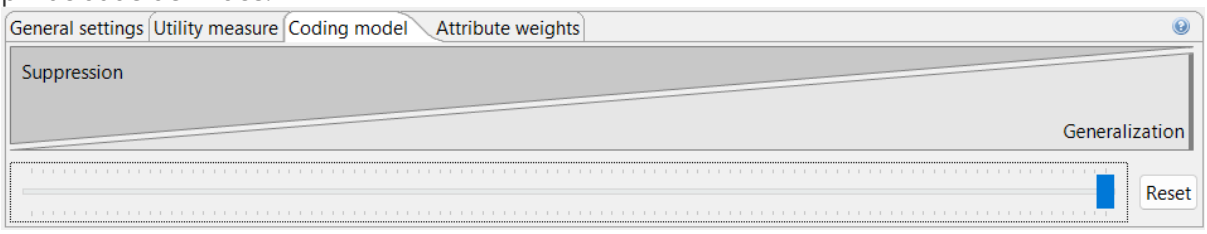

1.3.3 Peso de Atributos e Métrica de Utilidade

A métrica de utilidade selecionada é a **Loss**, que quantifica a perda de informação resultante da generalização e supressão.

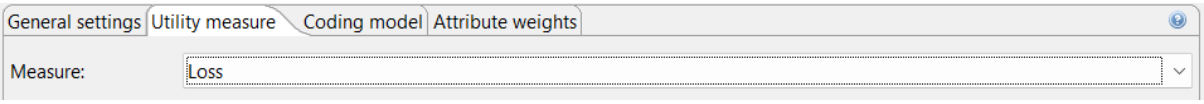

Dado o objetivo de divulgação (Age × CreditScore), o atributo **Age** receberá **peso máximo (1.0)**, de forma a minimizar a sua generalização. Os restantes QIDs mantêm o peso por defeito (0.5). O atributo CreditScore, sendo classificado como sensível, não é generalizado - é protegido pelos modelos de privacidade (ℓ-diversity e t-closeness).

1.3.4 Modelos Selecionados

Serão utilizados dois modelos de privacidade:

1. **k-Anonymity + ℓ-Diversity** - proteção contra identity disclosure e attribute disclosure
2. **k-Anonymity + t-Closeness** - proteção contra identity disclosure e attribute disclosure com controlo da distribuição

---

2. Caracterização do Dataset e Coding Models

2.1 Caracterização de Atributos

A classificação dos 14 atributos seguiu as categorias standard:

Identificadores (removidos do dataset):

- **RowNumber** - número sequencial, identifica diretamente a linha
- **CustomerId** - identificador único do cliente
- **Surname** - apelido pessoal

Quasi-identificadores (QID):

- **Age** - forte separação (96.9%) e distinção (0.7%) individual; em combinação com outros atributos, apresenta os maiores valores de distinção
- **Tenure** - alta separação (90.4%), com distribuição uniforme que contribui para a distinguibilidade
- **Geography** - em combinação com Age, a distinção sobe significativamente (Geography, Age: 1.96% distinção, 98.82% separação)
- **Gender** - contribui para o aumento da separação em combinação com Age
- **IsActiveMember** - combinações com Age e Geography mostram distinção relevante

Sensíveis:

- **CreditScore** - pontuação financeira pessoal, atributo central do objetivo de divulgação. Com 460 valores únicos, permite proteção eficaz via ℓ-diversity e t-closeness.
- **Balance** - saldo bancário, informação financeira que os clientes desejam manter privada (~6382 valores únicos).
- **EstimatedSalary** - salário estimado, dado financeiro pessoal (~9999 valores únicos).

Insensíveis:

- **HasCrCard** - binário, baixa distinção e separação individual e em combinação; não se evidencia como diferenciador em conjuntos de atributos.
- **NumOfProducts** - apenas 4 valores únicos, contribuição mínima para reidentificação.
- **Exited** - binário, baixa distinção.

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%

Quasi-identifier	Distinction	Separation
Gender	0.02%	49.58726%

Quasi-identifier	Distinction	Separation
Age	0.7%	96.89822%

Quasi-identifier	Distinction	Separation
Tenure	0.11%	90.39774%

Quasi-identifier	Distinction	Separation
IsActiveMember	0.02%	49.95939%

Fig. com análise de distinção e separação individual

Quasi-identifier	Distinction	Separation
Tenure	0.11%	90.39774%
Age	0.7%	96.89822%
Age, Tenure	6.5%	99.70316%

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%
Age	0.7%	96.89822%
Geography, Age	1.96%	98.81936%

Quasi-identifier	Distinction	Separation
Gender	0.02%	49.58726%
Age	0.7%	96.89822%
Gender, Age	1.35%	98.42979%

Fig. com análise de distinção e separação para pares de atributos

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%
Tenure	0.11%	90.39774%
Age	0.7%	96.89822%
Geography, Tenure	0.33%	96.38668%
Geography, Age	1.96%	98.81936%
Age, Tenure	6.5%	99.70316%
Geography, Age, Tenure	15.95%	99.88705%

Quasi-identifier	Distinction	Separation
IsActiveMember	0.02%	49.95939%
Geography	0.03%	62.43544%
Age	0.7%	96.89822%
Geography, IsActiveMember	0.06%	81.19772%
Age, IsActiveMember	1.31%	98.44353%
Geography, Age	1.96%	98.81936%
Geography, Age, IsActiveMember	3.62%	99.40764%

Fig. com análise de distinção e separação para trios de atributos

Justificação da escolha de HasCrCard como insensível: Ao contrário de atributos como Gender e IsActiveMember, HasCrCard não apresenta aumentos significativos de distinção ou separação quando combinado com outros atributos. A sua contribuição marginal para a reidentificação é mínima, justificando a sua classificação como insensível em vez de QID. Isto reduz o espaço de generalização necessário, melhorando a utilidade do dataset anonimizado.

2.2 Riscos de Privacidade do Dataset Original

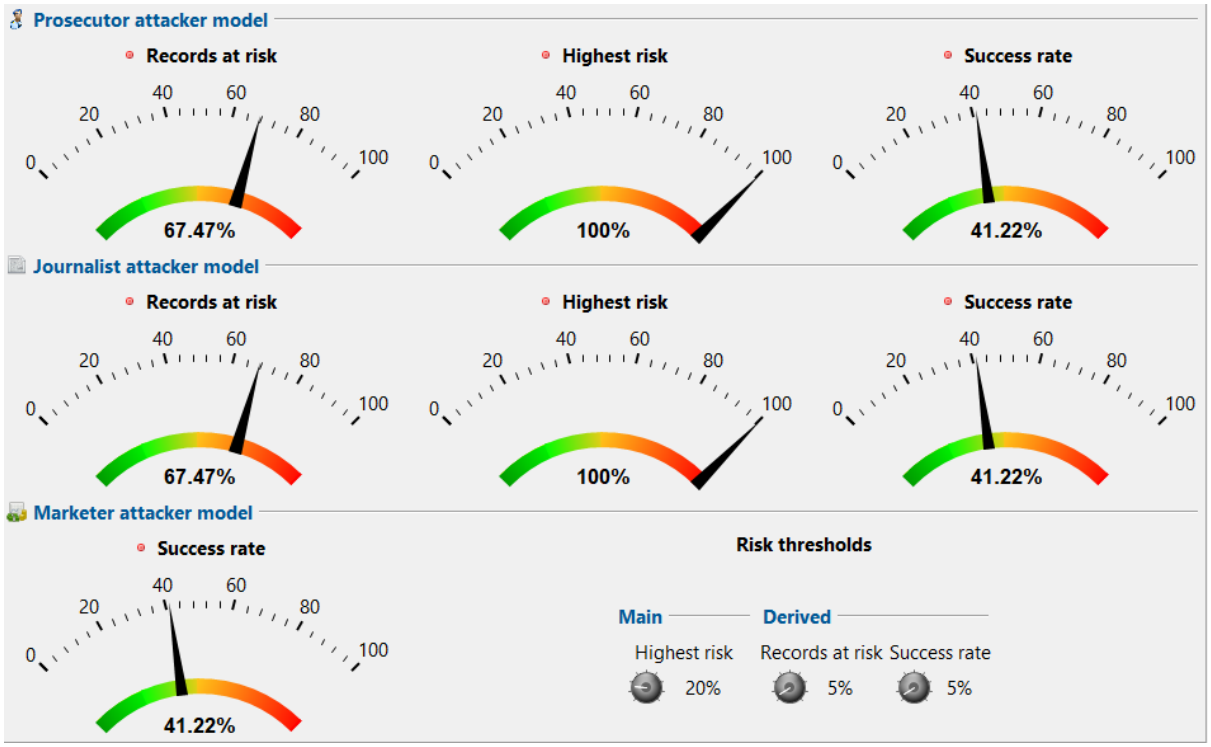

Fig. Re-identification risks (antes da anonimização

Os riscos de reidentificação do dataset original foram analisados sob três modelos de ataque:

Modelo de Ataque	Records at Risk	Highest Risk	Success Rate
Prosecutor	67.47%	100%	41.22%
Journalist	67.47%	100%	41.22%
Marketer	-	-	41.22%

Os valores mostram que o dataset original apresenta riscos de reidentificação muito elevados, com 67.47% dos registos em risco e um risco máximo de 100%, confirmando a necessidade de anonimização.

2.3 Distribuição de Atributos

Excluindo atributos binários e o atributo Geography (3 valores), a análise de distribuição focou-se nos atributos com maior variabilidade:

- **Age:** concentração entre 25 e 50 anos, com uma cauda longa até aos 92 anos. Esta assimetria é relevante para o desenho da hierarquia.

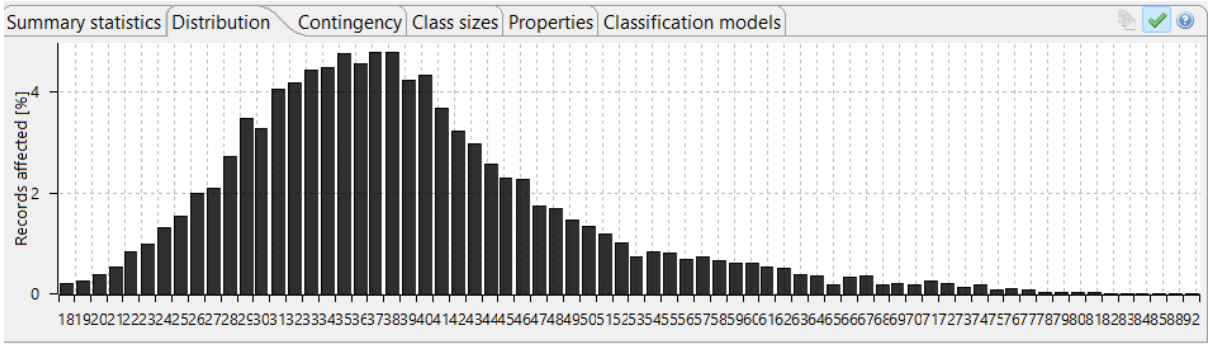

Fig. distribuição de Age no ARX

- **Tenure:** distribuição aproximadamente uniforme entre 0 e 10 anos (com ligeiro decréscimo em 0 e 10).

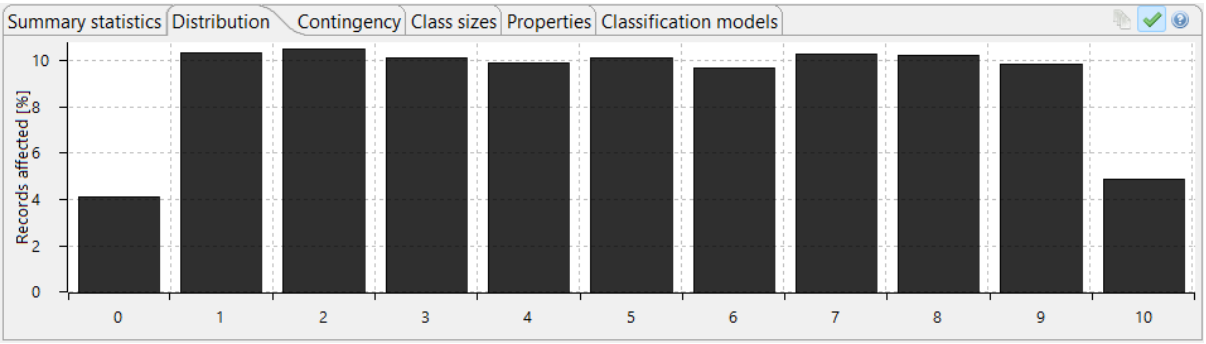

Fig. distribuição de Tenure no ARX

2.4 Criação de Hierarquias

As hierarquias foram desenhadas tendo em conta a distribuição de cada QID e o objetivo de divulgação.

Age (hierarquia por intervalos, baseada na distribuição assimétrica):

Nível 0	**Nível 1**	**Nível 2**	**Nível 3**
18–92 (original)	[18,25[, [25,35[, [35,45[, [45,55[, [55,93[	[18,35[, [35,55[, [55,93[	[18,93[

Os cortes do Nível 1 correspondem às faixas etárias utilizadas na estatística-alvo. O intervalo [18,25[é mais curto por conter menos registos; o intervalo [55,93[é mais amplo por agrupar a cauda longa da distribuição.

Level-0	Level-1	Level-2	Level-3
18	[18, 25[	[18, 35[	[18, 93[
19	[18, 25[	[18, 35[	[18, 93[
20	[18, 25[	[18, 35[	[18, 93[
21	[18, 25[	[18, 35[	[18, 93[
22	[18, 25[	[18, 35[	[18, 93[
23	[18, 25[	[18, 35[	[18, 93[
24	[18, 25[	[18, 35[	[18, 93[
25	[25, 35[	[18, 35[	[18, 93[
26	[25, 35[	[18, 35[	[18, 93[
27	[25, 35[	[18, 35[	[18, 93[
28	[25, 35[	[18, 35[	[18, 93[
29	[25, 35[	[18, 35[	[18, 93[
30	[25, 35[	[18, 35[	[18, 93[
31	[25, 35[	[18, 35[	[18, 93[
32	[25, 35[	[18, 35[	[18, 93[
33	[25, 35[	[18, 35[	[18, 93[
34	[25, 35[	[18, 35[	[18, 93[

Diagrama/screenshot da hierarquia de Age

Tenure (hierarquia por intervalos uniformes):

Nível 0	**Nível 1**	**Nível 2**	**Nível 3**
0–10 (original)	[0,3[, [3,6[, [6,9[, [9,12[	[0,6[, [6,12[	[0,12[

Level-0	Level-1	Level-2	Level-3
0	[0, 3[	[0, 6[	[0, 12[
1	[0, 3[	[0, 6[	[0, 12[
2	[0, 3[	[0, 6[	[0, 12[
3	[3, 6[	[0, 6[	[0, 12[
4	[3, 6[	[0, 6[	[0, 12[
5	[3, 6[	[0, 6[	[0, 12[
6	[6, 9[	[6, 12[	[0, 12[
7	[6, 9[	[6, 12[	[0, 12[
8	[6, 9[	[6, 12[	[0, 12[
9	[9, 12[	[6, 12[	[0, 12[
10	[9, 12[	[6, 12[	[0, 12[

Diagrama/screenshot da hierarquia de Tenure

Geography (hierarquia categórica):

Nível 0	**Nível 1**	**Nível 2**
France	Western Europe	Europe
Germany	Western Europe	Europe
Spain	Southern Europe	Europe

Level-0	Level-1	Level-2
France	Western Europe	Europe
Germany	Western Europe	Europe
Spain	Southern Europe	Europe

Hierarquia de Geography

Gender e **IsActiveMember** (binários): Apenas um nível de generalização possível (valor original → *).

2.5 Peso de Atributos

Dado o objetivo de divulgação (CreditScore médio por faixa etária), atribui-se **peso 1.0 ao atributo Age**. Esta decisão visa minimizar a perda de informação neste atributo durante a anonimização, uma vez que é o QID com maior impacto na utilidade da estatística-alvo.

Os restantes QIDs mantêm o peso por defeito (0.5).

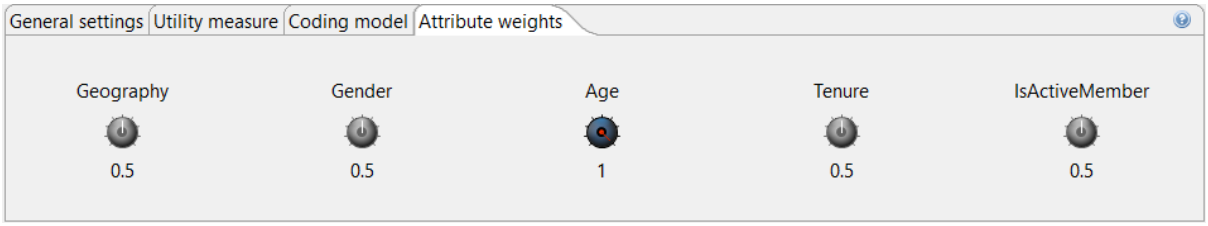

Pesos de atributos no ARX

---

3. Modelos de Privacidade: Utilidade, Privacidade e Avaliação de Risco

3.1 k-Anonymity e ℓ-Diversity

A primeira abordagem combina k-Anonymity com ℓ-Diversity. O atributo sensível principal protegido por ℓ-diversity é o **CreditScore** (460 valores únicos), complementado por Balance e EstimatedSalary.

3.1.1 Escolha de k (para ℓ = 2)

Iniciou-se a análise com ℓ fixo (ℓ = 2 para todos os atributos sensíveis), variando k entre 5, 10, 15 e 18. As métricas avaliadas foram:

- Highest Risk e Success Rate (privacidade)
- Loss Score (utilidade principal)
- N.-U. Entropy (semelhança das distribuições)
- Discernibility (tamanho das classes de equivalência)
- Record-level e Attribute-level Squared Error (qualidade dos dados)
- Suppressed Records (percentagem de supressão)

Para cada valor de k, aplicou-se a transformação ótima sugerida pelo ARX (com a métrica Loss selecionada). A Tabela 2 resume as transformações ótimas e os resultados obtidos.

Tabela 2: Transformações ótimas por valor de k (ordem: Geography, Gender, Age, Tenure, IsActiveMember).

k	Transformação ótima	Generalização de Age
5	[0, 0, 2, 0, 0]	Nível 2 - 3 faixas: [18,35[, [35,55[, [55,93[
10	[0, 0, 1, 1, 0]	Nível 1 - 5 faixas: [18,25[, [25,35[, [35,45[, [45,55[, [55,93[
15	[1, 0, 1, 1, 0]	Nível 1 - 5 faixas (Geography generalizado ao nível 1)
18	[0, 0, 3, 1, 0]	Nível 3 - 1 faixa: [18,93[(toda a informação de Age perdida)

Tabela 3: Métricas de utilidade e privacidade por valor de k.

Métrica	k=5	k=10	k=15	k=18
Loss Score (%)	1.55	2.74	2.79	0.00*
N.-U. Entropy (%)	66.47	59.33	53.79	44.58
Discernibility (%)	98.11	96.59	96.05	97.51
Record-level Squared Error (%)	78.19	82.56	75.82	23.73
Attribute-level Squared Error (%)	91.04	92.86	92.62	1.97
Highest Risk (%)	20.00	10.00	6.25	1.61
Success Rate (%)	3.40	2.01	1.30	0.48
Suppressed Records (%)	1.52	2.69	2.74	0.00

** O Loss Score de 0% para k=18 é enganador: deve-se ao facto de Age ser totalmente generalizado (nível 3), eliminando a variabilidade deste atributo e, consequentemente, a utilidade para o objetivo de divulgação.*

[INSERIR: Gráfico comparativo das métricas para k = 5, 10, 15, 18 com ℓ = 2]

Análise dos resultados:

De **k=5 para k=10**, observa-se uma descida significativa do Highest Risk (de 20% para 10%) com um aumento moderado do Loss Score (de 1.55% para 2.74%). Além disso, a transformação ótima para k=10 generaliza Age apenas ao nível 1 (5 faixas etárias), enquanto k=5 necessita do nível 2 (3 faixas). Isto torna k=10 mais favorável para o objetivo de divulgação, apesar do Loss Score ligeiramente superior.

De **k=10 para k=15**, o Loss Score praticamente não se altera (2.74% → 2.79%), enquanto o Highest Risk desce consideravelmente (10% → 6.25%). O custo é a generalização de Geography ao nível 1 (Western Europe / Southern Europe), mas Age mantém-se no nível 1, preservando as 5 faixas etárias necessárias para a análise.

Para **k=18**, a transformação ótima generaliza Age ao nível 3 (um único intervalo [18, 93[), o que **elimina completamente a possibilidade de calcular o CreditScore médio por faixa etária**. Embora os riscos de reidentificação sejam muito baixos (Highest Risk de 1.61%), esta configuração é incompatível com o objetivo de divulgação definido. O mesmo se aplica a valores de k superiores (k=20), que foram descartados pelo mesmo motivo.

Conclusão: O valor **k=15** apresenta o melhor equilíbrio entre privacidade e utilidade para o objetivo definido. Oferece riscos de reidentificação aceitáveis (Highest Risk de 6.25%, Success Rate de 1.30%), uma percentagem de supressão dentro do limite definido (2.74% < 3%), e preserva Age ao nível 1, permitindo a análise do CreditScore por 5 faixas etárias.

3.1.2 Escolha de ℓ

Com k=15 fixo, variou-se o valor de ℓ para o atributo sensível principal (CreditScore), mantendo ℓ=2 para Balance e EstimatedSalary. Foram testados os valores ℓ=2, 3 e 5 para CreditScore.

Para todos os valores testados, a transformação ótima, as métricas de utilidade e os riscos de reidentificação **mantiveram-se inalterados** - exatamente os mesmos valores que para ℓ=2.

Este resultado explica-se pela **elevada cardinalidade do CreditScore** (460 valores únicos) combinada com o **tamanho mínimo das classes de equivalência** (16 registos para k=15). Cada classe de equivalência contém naturalmente uma grande diversidade de valores de CreditScore, satisfazendo a condição de ℓ-diversity sem necessidade de generalização adicional, mesmo para valores de ℓ relativamente elevados.

Esta observação demonstra que, para este dataset e esta configuração, **o fator determinante na anonimização é o valor de k**, não o valor de ℓ. O k-anonymity, por si só, já garante diversidade suficiente nos atributos sensíveis.

3.1.3 Resultados

A configuração final do Modelo 1 é **k=15, ℓ=2** para CreditScore, Balance e EstimatedSalary, com a transformação [1, 0, 1, 1, 0]:

Atributo	**Nível de Generalização**	**Resultado**
Geography	1	Western Europe / Southern Europe
Gender	0	Sem generalização
Age	1	[18,25[, [25,35[, [35,45[, [45,55[, [55,93[
Tenure	1	[0,3[, [3,6[, [6,9[, [9,12[
IsActiveMember	0	Sem generalização

Métricas de utilidade finais:

Métrica	Valor
Loss Score (%)	2.79
N.-U. Entropy (%)	53.79
Discernibility (%)	96.05
Record-level Squared Error (%)	75.82
Attribute-level Squared Error (%)	92.62
Suppressed Records (%)	2.74

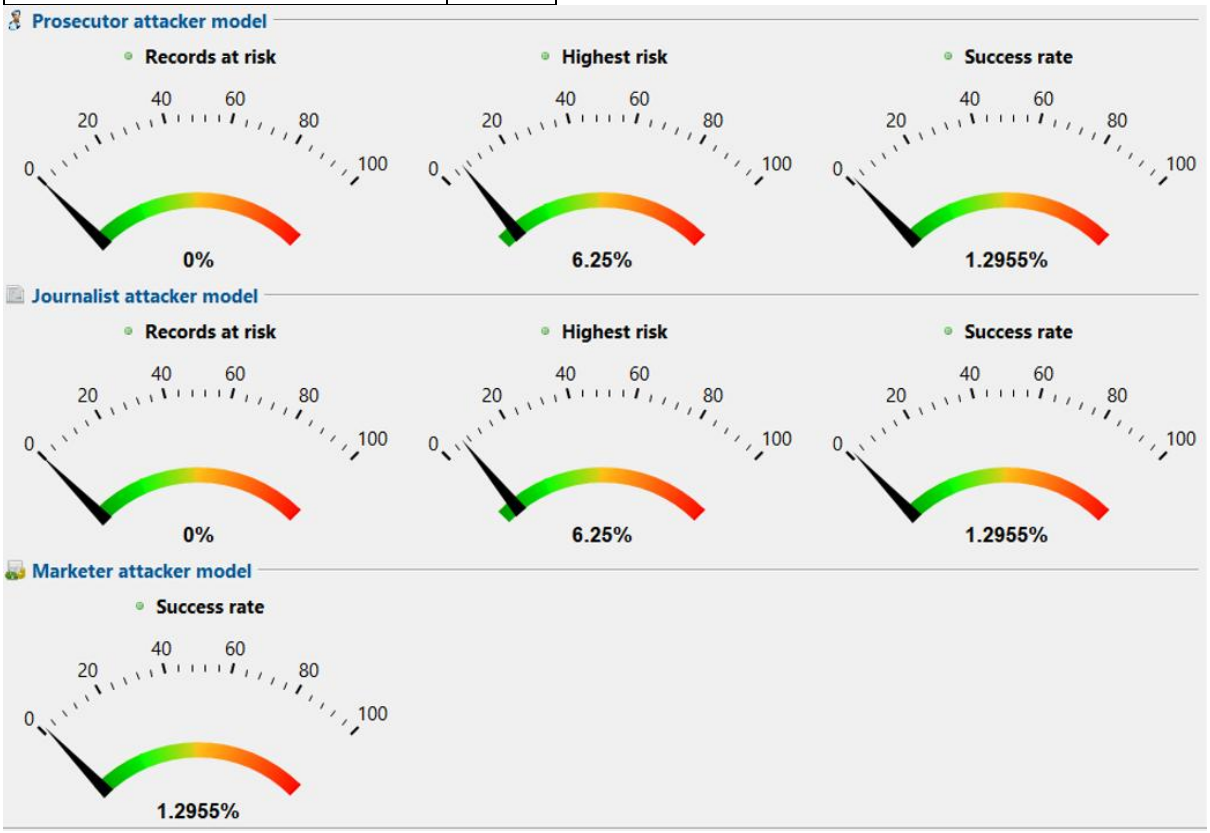

Riscos de reidentificação após anonimização:

Modelo de Ataque	Records at Risk	Highest Risk	Success Rate
Prosecutor	0%	6.25%	1.30%
Journalist	0%	6.25%	1.30%
Marketer	-	-	1.30%

Estatística-alvo - CreditScore médio por faixa etária:

Faixa Etária	CreditScore Original	CreditScore Anonimizado	Diferença
[18, 25[	653.97	656.21	+2.24
[25, 35[	651.33	651.33	0.00
[35, 45[	650.87	650.87	0.00
[45, 55[	645.79	645.91	+0.12
[55, 93[	652.11	650.76	-1.35

Tabela 4: Comparação entre CreditScore médio do dataset original e anonimizado por faixa etária.

A anonimização preservou com eficácia a utilidade dos dados. As faixas centrais ([25,35[e [35,45[) apresentam valores **idênticos** aos originais, enquanto as faixas extremas mostram diferenças mínimas (máximo de 2.24 pontos). Estas pequenas variações devem-se à supressão de 274 registos (2.74%), que afetou predominantemente as faixas com menos registos.

3.2 k-Anonymity e t-Closeness

A segunda abordagem combina k-Anonymity com t-Closeness, que garante que a distribuição do atributo sensível dentro de cada classe de equivalência não difere mais do que t da distribuição global. Isto oferece proteção contra ataques de *skewness* e *similarity*, complementando a proteção fornecida pela ℓ-diversity.

3.2.1 Análise Preliminar

Testaram-se diversas configurações, aplicando t-closeness aos três atributos sensíveis (CreditScore, Balance e EstimatedSalary) com o mesmo valor de t. Os valores de t testados variaram entre 0.15 e 0.30, para k=5, 10 e 15.

Configuração	k	t	Transformação ótima	Age
t-Closeness (3 sensíveis)	5	0.15	[2, 1, 3, 3, 1]	Nível 3 (máx.)
t-Closeness (3 sensíveis)	5	0.20	[2, 1, 3, 3, 1]	Nível 3 (máx.)
t-Closeness (3 sensíveis)	10	0.25	[2, 1, 3, 3, 1]	Nível 3 (máx.)
t-Closeness (3 sensíveis)	15	0.30	[2, 1, 3, 3, 1]	Nível 3 (máx.)

Em **todas as configurações testadas**, a transformação ótima generalizou todos os QIDs ao nível máximo, resultando numa única classe de equivalência com 10.000 registos e utilidade nula. O t-closeness aplicado simultaneamente aos três atributos sensíveis revelou-se excessivamente restritivo para este dataset.

3.2.2 Abordagem Híbrida

Face aos resultados anteriores, adotou-se uma **abordagem híbrida**: aplicar t-closeness apenas ao atributo sensível diretamente relacionado com o objetivo (CreditScore) e ℓ-diversity (ℓ=2) aos restantes (Balance e EstimatedSalary). Esta abordagem é justificável porque concentra a proteção distribucional mais forte no atributo crítico para a análise.

Configuração	k	t (CS)	ℓ (Bal, ES)	Transformação	Age
Híbrida	15	0.20	2	[2, 0, 3, 3, 0]	Nível 3
Híbrida	15	0.30	2	[2, 0, 3, 3, 0]	Nível 3
Híbrida	15	0.50	2	[0, 0, 3, 3, 0]	Nível 3

Mesmo com a abordagem híbrida e valores de t até 0.50, o ARX é sistematicamente forçado a generalizar Age ao nível 3 (um único intervalo [18, 93[), eliminando a possibilidade de calcular o CreditScore por faixa etária.

3.2.3 Interpretação

O t-closeness revelou-se **incompatível com o objetivo de divulgação** deste dataset. Este resultado, embora inicialmente contraintuitivo, tem uma explicação clara:

O t-closeness exige que a distribuição do CreditScore dentro de cada classe de equivalência seja semelhante à distribuição global (com distância EMD ≤ t). Ora, a distribuição do CreditScore **varia entre faixas etárias** - a faixa [45,55[apresenta uma média mais baixa (645.79) que as restantes. Para satisfazer a condição de t-closeness, o ARX é forçado a agrupar todas as idades num único intervalo, de forma a que cada classe contenha uma mistura representativa de todas as faixas etárias.

Existe, portanto, um **trade-off fundamental**: o t-closeness protege contra a inferência de atributos sensíveis a partir da distribuição dentro de cada grupo, mas essa proteção é atingida precisamente ao eliminar as diferenças distribucionais entre grupos - que são exatamente o que o objetivo de divulgação pretende preservar.

Nota sobre o trabalho de referência: O trabalho de Maria Sousa Carreira e Matilde Simões (2024/2025), que utilizou o mesmo dataset com o objetivo de analisar Salário × Idade, conseguiu aplicar t-closeness com t=0.30 e k=18. Isto foi possível porque o EstimatedSalary tem uma distribuição uniforme que varia pouco entre faixas etárias, ao contrário do CreditScore que apresenta variações distribucionais mais acentuadas. Esta diferença ilustra como a adequação do modelo de privacidade depende criticamente da relação entre o atributo sensível e os quasi-identificadores.

3.2.4 Resultados da Melhor Configuração Encontrada

Dado que o t-closeness não permite preservar o objetivo de divulgação, apresentam-se os resultados da configuração com **t=0.50 (híbrida)**, que representa o cenário mais relaxado testado:

Transformação: [0, 0, 3, 3, 0] - Age nível 3, Tenure nível 3, restantes sem generalização.

Métrica	**Valor**
Loss Score (%)	0.00*
N.-U. Entropy (%)	28.60
Discernibility (%)	90.54
Record-level Squared Error (%)	14.86
Attribute-level Squared Error (%)	0.17
Suppressed Records (%)	0.00
Highest Risk (%)	0.19
Success Rate (%)	0.12

** Loss Score de 0% indica que Age e Tenure estão totalmente generalizados.*

Embora os riscos de reidentificação sejam extremamente baixos, a estatística-alvo não pode ser calculada - todos os clientes pertencem à mesma faixa etária [18, 93[, impossibilitando qualquer segmentação.

3.3 Comparação dos Modelos

Métrica	**k-Anon + ℓ-Diversity**	**k-Anon + t-Closeness**
Configuração	k=15, ℓ=2	k=15, t=0.50 (CS), ℓ=2 (Bal, ES)
Transformação	[1, 0, 1, 1, 0]	[0, 0, 3, 3, 0]
Loss Score (%)	2.79	0.00*
N.-U. Entropy (%)	53.79	28.60

Métrica	k-Anon + ℓ-Diversity	k-Anon + t-Closeness
Discernibility (%)	96.05	90.54
Highest Risk (%)	6.25	0.19
Success Rate (%)	1.30	0.12
Suppressed Records (%)	2.74	0.00
Generalização Age	**Nível 1 (5 faixas)**	**Nível 3 (1 faixa)**
Objetivo preservado?	**Sim**	**Não**

Análise comparativa:

O modelo k-Anonymity + t-Closeness oferece riscos de reidentificação significativamente mais baixos (Highest Risk de 0.19% vs. 6.25%), mas este ganho em privacidade é obtido ao custo de **destruir completamente a utilidade para o objetivo definido**. O t-closeness força a generalização total de Age, impedindo qualquer segmentação etária.

O modelo k-Anonymity + ℓ-Diversity, com k=15, constitui a única abordagem viável para este cenário. Preserva as 5 faixas etárias com diferenças mínimas no CreditScore médio (máximo 2.24 pontos), mantendo riscos de reidentificação aceitáveis e supressão dentro do limite de 3%.

3.4 Recomendação Final

Recomenda-se a adoção do modelo **k-Anonymity (k=15) + ℓ-Diversity (ℓ=2)** para a divulgação deste dataset, com a transformação [1, 0, 1, 1, 0]. Esta configuração:

- **Preserva o objetivo de divulgação** - CreditScore médio por faixa etária mantém diferenças inferiores a 2.3 pontos face ao original.
- **Garante privacidade adequada** - Highest Risk de 6.25%, Success Rate de 1.30%, 0% de records at risk.
- **Minimiza a perda de informação** - Loss Score de 2.79%, supressão de 2.74%.
- **É robusta** - variações no valor de ℓ não alteram os resultados, indicando que a proteção é determinada pelo k-anonymity.

O t-closeness, embora teoricamente mais forte, revelou-se impraticável para este cenário específico, onde o objetivo de divulgação depende precisamente das diferenças distribucionais que o modelo procura eliminar.

---

4. Anexos

4.1 Distribuição do Dataset

[distribution-histogram.py]

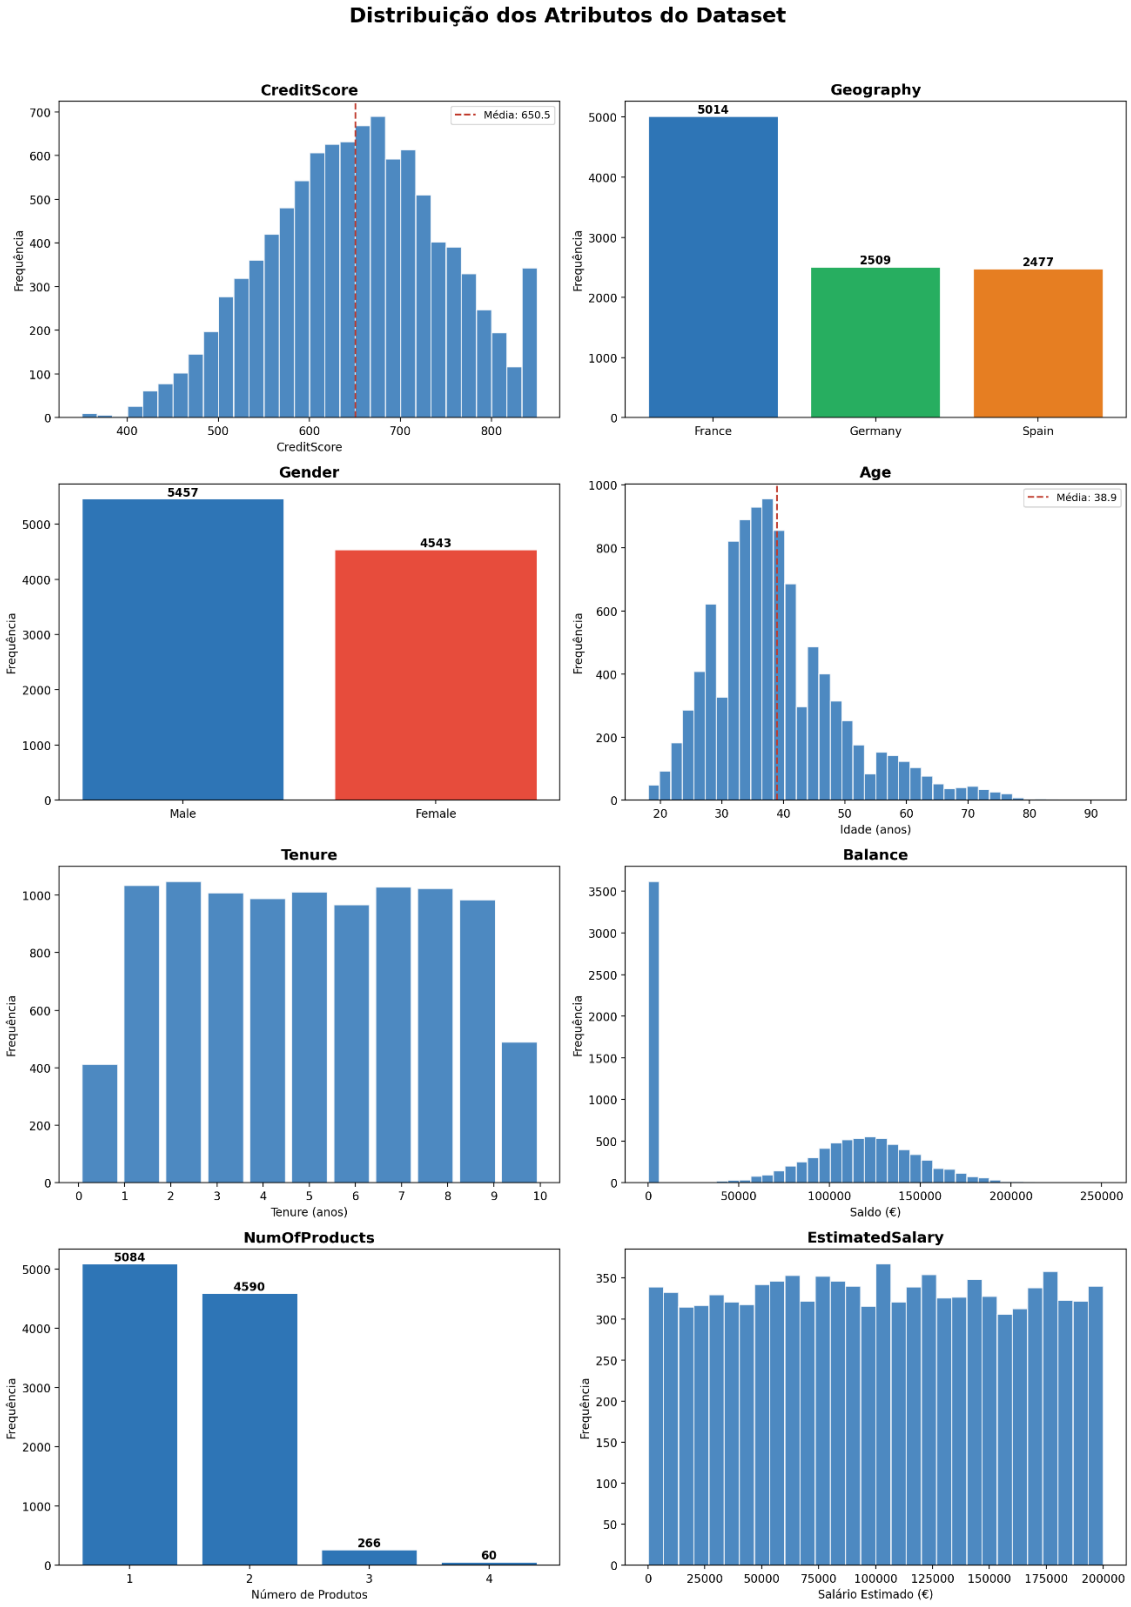

4.2 Qualidade e Conformidade dos Dados

```python
import pandas as pd

data = pd.read_csv('Churn_Modelling.csv')

# Contagem de Valores Nulos
print(data.isnull().sum())

# Contagem de Valores Únicos
print(data.nunique())

# Valores Únicos de atributos categóricos
print(data['Geography'].unique())  # ['France', 'Spain', 'Germany']
print(data['Gender'].unique())     # ['Female', 'Male']

# Registos duplicados
print(f"Duplicados: {data.duplicated().sum()}")  # 0
```

4.3 Estatística-Alvo (CreditScore médio por faixa etária)

```python
import pandas as pd

data = pd.read_csv('Churn_Modelling.csv')
bins = [18, 25, 35, 45, 55, 93]
labels = ['[18,25[', '[25,35[', '[35,45[', '[45,55[', '[55,93[']
data['FaixaEtaria'] = pd.cut(data['Age'], bins=bins, right=False, labels=labels)
result = data.groupby('FaixaEtaria')['CreditScore'].agg(['mean','count']).round(2)
print(result)
```

Faixa Etária	CreditScore Médio	Contagem
[18, 25[	653.97	457
[25, 35[	651.33	3222
[35, 45[	650.87	3981
[45, 55[	645.79	1458
[55, 93[	652.11	882