UNIVERSIDADE DO PORTO

RELATÓRIO – TECNOLOGIAS DE REFORÇO DA PRIVACIDADE

Anonimização de um dataset com análise de privacidade, utilidade e risco.

Autores:

João FILIPE - 202408782

Tiago MONTEIRO - 202108391

Faculdade de Ciências da Universidade do Porto

Departmento de Ciências da Computação

29 de março de 2026

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto
Departmento de Ciências da Computação

Mestrado em Segurança Informática

Anonimização de um dataset com análise de privacidade, utilidade e risco.

by João FILIPE - 202408782
Tiago MONTEIRO - 202108391

Este projeto detalha o processo de anonimização do *dataset "Predicting Churn for Bank Customers"*, visando o equilíbrio ótimo entre a privacidade dos utilizadores e a utilidade analítica. O objetivo central consistiu em mitigar o risco de reidentificação, garantindo simultaneamente a viabilidade estatística da correlação entre faixas etárias (*Age*) e o risco de crédito (*CreditScore*). Utilizando o *ARX*, compararam-se duas abordagens: o Modelo 1 (*k-anonymity* e *l-diversity*) e o Modelo 2 (*k-anonymity* e *t-closeness*). A análise demonstra que o Modelo 2, é a solução arquitetural superior. Esta configuração mitiga com sucesso ataques de inferência semântica em dados financeiros, exigindo apenas sacrifícios controlados em atributos secundários.

Palavras-chave: Anonimização de Dados, Privacidade, *k*-Anonymity, *l*-Diversity, *t*-Closeness, ARX.

Conteúdo

Abstract i

Conteúdo ii

Lista de Tabelas iv

Lista de Figuras v

1 Introdução 1
1.1 Contexto e Motivação . . . 1
1.2 Objetivos do Trabalho e Estrutura do Relatório . . . 1

2 Seleção, Importação e Objetivo do Dataset 3
2.1 Seleção do Dataset . . . 3
2.2 Análise dos Atributos do Dataset . . . 3
2.2.1 Distribuições dos Valores dos Atributos . . . 4
2.2.2 Sanitização . . . 5
2.3 Objetivo de Divulgação do Dataset . . . 5
2.4 Requisitos de Privacidade . . . 6
2.4.1 Limite de Supressão . . . 6
2.4.2 Coding Model . . . 6
2.4.3 Peso de Atributos e Métrica de Utilidade . . . 7
2.4.4 Modelos de Privacidade Selecionados . . . 7

3 Caracterização do Dataset e Coding Models 8
3.1 Caracterização de Atributos . . . 8
3.1.1 Identificadores . . . 8
3.1.2 Quasi-Identifiers (QIDs) . . . 9
3.1.3 Atributos Sensíveis . . . 10
3.1.4 Atributos Insensíveis . . . 11
3.2 Riscos de Privacidade do Dataset Original . . . 11
3.3 Distribuição de Atributos . . . 12
3.4 Criação de Hierarquias . . . 13
3.4.1 Age . . . 13
3.4.2 Tenure . . . 14
3.4.3 Geography . . . 15

3.4.4 Gender e IsActiveMember 15
3.5 Peso dos Atributos 16

4 Modelos de Privacidade: Utilidade, Privacidade e Avaliação de Risco 17
4.1 k-Anonymity e l-Diversity 17
4.2 Aplicação do Modelo 1 17
4.2.1 Exploração e Escolha do Parâmetro K 18
4.2.1.1 Análise dos resultados e Escolha de K 19
4.2.2 Exploração e Escolha do Parâmetro L 20
4.2.3 Resultados do Modelo 1 20
4.2.3.1 Riscos de Re-identificação Após Modelo 1 21
4.2.3.2 Análise dos Resultados 21
4.3 k-Anonymity e t-Closeness 22
4.4 Aplicação do Modelo 2 23
4.4.1 Resultados do Modelo 2 23
4.4.1.1 Riscos de Re-identificação Após Modelo 2 24
4.4.1.2 Análise dos Resultados 25

5 Reflexões finais e Conclusão 26
5.1 Comparação dos Modelos 26
5.2 Recomendações de Consultoria 27
5.3 Conclusão 27

A Anexos 28

Bibliography 30

Lista de Tabelas

2.1 Descrição e tipologia dos atributos presentes no *dataset* de clientes bancários. 4
2.2 Análise das faixas etárias em função do *Credit Score* médio no dataset original. 6

3.1 Análise dos riscos relativos a diferentes ataques 12
3.2 Hierarquias criadas para o atributo de idade 13
3.3 Hierarquias criadas para o atributo de tenure 14
3.4 Hierarquias criadas para o atributo *Geography* 15
3.5 Hierarquias criadas para o atributos *Gender* e *IsActiveMember* 15

4.1 Transformações ótimas por valor de k (ordem: Geography, Gender, Age, Tenure,IsActiveMember).. 18
4.2 Métricas de utilidade e privacidade por valor de *k*. 19
4.3 Níveis de generalização aplicados aos QIDs na configuração ótima selecionada para o primeiro modelo. 21
4.4 Comparação do *CreditScore* médio entre o *dataset* original e o anonimizado, por faixa etária no primeiro dataset anonimizado. 22
4.5 Resultados da aplicação preliminar de *t*-closeness a todos os atributos sensíveis em simultâneo. 23
4.6 Resultado final ótimo da aplicação individualizada do *t-closeness*. 23
4.7 Níveis de generalização aplicados aos Quase-Identificadores na configuração ótima do Modelo 2. 24
4.8 Comparação do *CreditScore* médio entre o *dataset* original e o anonimizado, por faixa etária no segundo dataset anonimizado. 25

Lista de Figuras

2.1 Representação visual da métrica de *coding model*. 7
2.2 Representação visual da métrica Loss 7

3.1 Análise de distinção e separação individual. 9
3.2 Análise de distinção e separação para pares de atributos. 10
3.3 Análise de distinção e separação para trios de atributos. 10
3.4 Riscos de re-identficação no modelo original. 12
3.5 Distribuição de idades visto no *ARX*. 13
3.6 Distribuição de tenure visto no *ARX*. 13
3.7 Amostra das hierarquias para idade criadas no *ARX*. 14
3.8 Amostra das hierarquias para tenure criadas no *ARX*. 15
3.9 Configuração dos pesos no *ARX*. 16

4.1 Riscos de re-identifcação após aplicar modelo 1. 21
4.2 Riscos de re-identifcação após aplicar modelo 2. 24

A.1 Distribuição do Dataset 29

Capítulo 1

Introdução

Este capítulo apresenta o contexto e a motivação subjacentes a este projeto. Adicionalmente, são delineados os principais objetivos do trabalho e a forma como o presente relatório se encontra estruturado.

1.1 Contexto e Motivação

Este projeto foi desenvolvido no âmbito da unidade curricular de *Tecnologias de Reforço de Privacidade*. Atualmente, a proliferação da recolha e processamento de dados pessoais expõe a privacidade dos utilizadores a riscos significativos. Muitas entidades falham na implementação de processos adequados de anonimização, quer por limitações técnicas ou pela necessidade de preservar a granularidade dos dados originais para maximizar a sua utilidade em áreas como machine learning, campanhas de marketing ou investigação. Neste contexto, torna-se crucial encontrar um trade-off aceitável e seguro entre a proteção da privacidade dos indivíduos e a utilidade analítica da informação.

1.2 Objetivos do Trabalho e Estrutura do Relatório

O objetivo central deste projeto consiste em realizar uma análise detalhada do processo de anonimização de um dataset. Para tal, o trabalho prático e este relatório encontram-se estruturados em quatro fases principais:

- **Seleção e Caracterização do Dataset**: A primeira fase abrange a seleção de um conjunto de dados com dimensão e riqueza suficientes para o processo , seguida da sua sanitização e importação para a ferramenta *ARX*. Inclui também a definição dos

objetivos analíticos para a publicação dos dados e o estabelecimento dos requisitos iniciais de privacidade, estipulando intervalos aceitáveis para os parâmetros de anonimização.

- **Modelos de Codificação:** A segunda parte foca-se na classificação dos atributos (insensíveis, sensíveis, *quasi-identifiers* e identificadores) e na análise da distribuição e dos riscos de privacidade na forma original do dataset. Com base nesta caracterização, procede-se à configuração dos modelos de codificação, nomeadamente através da definição das hierarquias e dos pesos dos atributos.

- **Modelos de Privacidade e Análise de Risco:** O terceiro ponto envolve a aplicação de dois modelos de privacidade distintos. Nesta secção, efetua-se uma análise iterativa para tentar equilibrar e otimizar os níveis de utilidade e de privacidade, acompanhada por uma avaliação detalhada do risco de reidentificação face aos objetivos inicialmente traçados.

- **Conclusões e Recomendações:** Por fim, o relatório documenta o raciocínio por detrás de todas as decisões tomadas. Assumindo uma perspetiva de consultoria de segurança, a secção final fornece um conjunto de recomendações práticas sobre o processo de anonimização a uma potencial entidade detentora destes dados.

Capítulo 2

Seleção, Importação e Objetivo do Dataset

2.1 Seleção do Dataset

Para a concretização deste projeto, foi selecionado o *dataset* *Predicting Churn for Bank Customers*, disponível publicamente na plataforma *Kaggle*. O objetivo primário para a publicação e utilização deste dataset enquadra-se no contexto de Machine Learning, visando o treino de modelos preditivos que permitam às instituições bancárias determinar a probabilidade de um cliente cessar a sua relação comercial (fenómeno de churn). O dataset é composto por **10000 registos** de clientes, englobando informação pessoal, demográfica e financeira. A natureza sensível de uma parte significativa destes dados torna-o interessante para a aplicação e avaliação de técnicas de anonimização, garantindo a proteção da privacidade sem comprometer a sua utilidade analítica.

2.2 Análise dos Atributos do Dataset

Numa fase inicial, procedeu-se à caracterização da estrutura dos dados, observando-se a presença de 14 atributos distintos na tabela 2.1.

Atributo	Descrição	Tipo
RowNumber	Número sequencial da linha	Inteiro
CustomerId	Identificador único do cliente	Inteiro
Surname	Apelido do Cliente	Texto
CreditScore	Pontuação financeira do cliente (350-850)	Inteiro
Geography	País de origem (France, Spain, Germany)	Categórico
Gender	Género (Male, Female)	Categórico
Age	Idade do cliente (18–92 anos)	Inteiro
Tenure	Tempo de ligação ao banco, em anos (0–10)	Inteiro
Balance	Saldo bancário do cliente (€)	Inteiro
NumOfProducts	Número de produtos bancários (1–4)	Inteiro
HasCrCard	Possui cartão de crédito (0/1)	Binário
IsActiveMember	Membro ativo (0/1)	Binário
EstimatedSalary	Salário anual estimado (€)	Inteiro
Exited	Abandonou o banco (0/1)	Binário

TABELA 2.1: Descrição e tipologia dos atributos presentes no *dataset* de clientes bancários.

2.2.1 Distribuições dos Valores dos Atributos

Para os atributos cuja natureza quantitativa ou categórica o justifica, efetuou-se uma análise estatística da distribuição dos valores com recurso à linguagem Python (consultar o Anexo A para uma análise mais detalhada). Destacam-se as seguintes conclusões:

- **CreditScore:** distribuição aproximadamente normal, com valores entre 350 e 850 e uma média de 650.5
- **Geography**: a maioria dos clientes reside em França (5014), seguida da Alemanha (2509) e Espanha (2477).
- **Gender**: distribuição relativamente equilibrada - 5457 homens e 4543 mulheres.
- **Age**: distribuição assimétrica, concentrada entre os 25 e 50 anos, com média de 38.9 anos.
- **Tenure**: distribuição aproximadamente uniforme entre 0 e 10 anos.

- **Balance**: um número significativo de clientes apresenta saldo nulo, os restantes distribuem-se de forma contínua.
- **NumOfProducts**: a maioria possui 1 ou 2 produtos, valores de 3 ou 4 são pouco frequentes.
- **EstimatedSalary**: distribuição uniforme, indicando ampla diversidade salarial.

2.2.2 Sanitização

A análise inicial confirmou a inexistência de valores nulos (ou em falta) em todos os atributos. Adicionalmente, todos os registos encontram-se em conformidade com os formatos esperados, ou seja, tipos de dados, intervalos e categorias válidas, não se registando qualquer entrada duplicada. Detetou-se que a precisão decimal (cêntimos) nos atributos *Balance* e *EstimatedSalary* era irrelevante para a macro-análise de risco e causava problemas de *parsing* no ARX devido aos separadores decimais. Estes valores foram devidamente arredondados e convertidos para números inteiros.

2.3 Objetivo de Divulgação do Dataset

Para a publicação deste *dataset* anonimizado, propõe-se que o mesmo seja utilizado para a **análise da correlação entre as diferentes faixas etárias dos clientes e o seu *Credit Score* médio**, garantindo, em absoluto, a proteção da privacidade individual.

Assumindo a perspetiva de um serviço profissional de consultoria, o objetivo prático é permitir que um departamento de risco bancário estude a influência da idade na pontuação de crédito. Simultaneamente, assegura-se que, caso este *dataset* seja libertado para o público em geral, nenhum atacante consiga reidentificar qualquer cliente ou inferir dados sensíveis com um nível de confiança elevada.

Faixa Etária	CreditScore Médio	no. clientes
[18, 25[	653.97	457
[25, 35[	651.33	3222
[35, 45[	650.87	3981
[45, 55[	645.79	1458
[55, 93[	652.11	882

TABELA 2.2: Análise das faixas etárias em função do *Credit Score* médio no dataset original.

Como é possível observar na Tabela 2.2, o *Credit Score* médio é relativamente estável entre as diferentes faixas etárias, registando-se uma ligeira descida na faixa dos [45, 55[. Esta estatística servirá como referência para avaliar a preservação da utilidade dos dados após o processo de anonimização.

2.4 Requisitos de Privacidade

Os requisitos de privacidade consistem na definição das restrições e limites aceitáveis para o processo de anonimização, tentando encontrar um *trade-off* ideal entre a máxima proteção dos titulares dos dados e a mínima perda de utilidade de informação útil para análise.

2.4.1 Limite de Supressão

Será aplicado um limite máximo de **supressão** de aproximadamente 4% dos registos. Este valor foi escolhido por equilibrar de forma eficaz a proteção da privacidade com a preservação da utilidade, sendo a supressão estritamente utilizada para eliminar *outliers* ou combinações raras de atributos que forçariam uma generalização excessiva de todo o conjunto de dados.

2.4.2 Coding Model

Dar-se-á preferência à **generalização**, por preservar a utilidade global dos dados de forma mais consistente. A supressão será aplicada apenas como último recurso para registos que violem os limites dos modelos de privacidade estipulados.

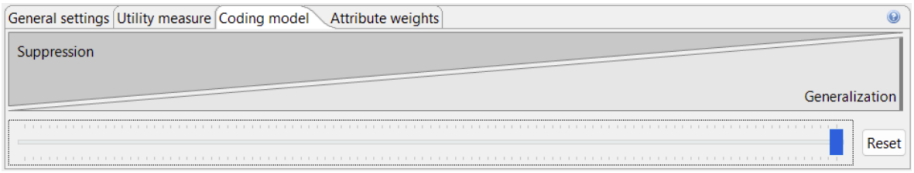

FIGURA 2.1: Representação visual da métrica de *coding model*.

2.4.3 Peso de Atributos e Métrica de Utilidade

A métrica de utilidade selecionada é a **Information Loss (Loss)**, que quantifica a perda de informação resultante dos processos de generalização e supressão.

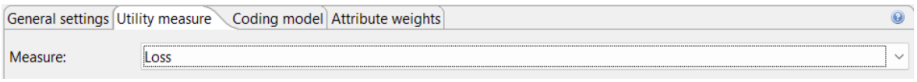

FIGURA 2.2: Representação visual da métrica Loss

Dado o objetivo analítico traçado (*Age* × *CreditScore*), o atributo **Age** (Idade) receberá o peso máximo (1.0). Desta forma, o algoritmo vai "penalizar"fortemente a perda de informação neste atributo, sendo forçado a minimizar a sua generalização. Os restantes Quase-Identificadores (QIDs) manterão o peso por defeito (0.5). O atributo **CreditScore**, classificado como sensível, não sofrerá generalização, sendo a sua proteção garantida pela aplicação direta dos modelos de privacidade (tais como *l*-diversity e *t*-closeness).

2.4.4 Modelos de Privacidade Selecionados

Para garantir a robustez da anonimização, serão explorados e comparados dois modelos de privacidade distintos:

- ***k*-Anonymity + *l*-Diversity:** Visa garantir a proteção contra *identity disclosure* (esconde o indivíduo numa **classe de equivalência** de tamanho *k*) e *attribute disclosure* (assegurando que existem pelo menos *l* valores distintos do atributo sensível dentro dessa mesma classe).

- ***k*-Anonymity + *t*-Closeness:** Fornece uma camada adicional de proteção semântica. Sendo o *Credit Score* um atributo numérico contínuo, o *t*-closeness assegura que a distribuição destes valores dentro de cada classe de equivalência se mantém próxima da distribuição global do *dataset*, mitigando ataques de distorção de distribuição.

Capítulo 3

Caracterização do Dataset e Coding Models

3.1 Caracterização de Atributos

Com base na análise inicial detalhada na Tabela 2.1, procedeu-se à classificação dos atributos em quatro categorias fundamentais para o processo de anonimização: **Identificadores** (atributos que identificam diretamente um indivíduo), **Quasi-Identifiers ou QIDs** (atributos que, embora não identifiquem diretamente, podem ser cruzados com outras bases de dados para re-identificar um indivíduo), **Sensíveis** (informação confidencial que deve ser protegida) e, por fim, atributos **Insensíveis** (dados que não representam risco de privacidade).

A classificação detalhada e a respetiva justificação são apresentadas de seguida:

3.1.1 Identificadores

Estes atributos identificam inequivocamente o cliente e, por conseguinte, serão **removidos** do *dataset* antes da publicação:

- **RowNumber:** Número sequencial que identifica diretamente a linha do registo.
- **CustomerId:** Identificador único atribuído ao cliente pela instituição bancária.
- **Surname:** Apelido pessoal do cliente.

3.1.2 Quasi-Identifiers (QIDs)

A seleção destes atributos baseou-se nas métricas de separação (*separation*) e distinção (*distinction*). Distinção neste contexto é o grau com que estes atributos tornam os registos distintos, já separação é o grau no qual a combinação de vários atributos separa os diferentes registos. Valores elevados de distinção e seperação indicam provavelmente QIDs.

- **Age:** Apresenta uma forte separação (96.9%) e distinção individual (0.7%). Em combinação com outros atributos, regista os maiores valores de distinção. Pode-se observar este comportamente nas figuras 3.1, 3.2 e 3.3.
- **Tenure:** Demonstra uma alta separação (90.4%), com uma distribuição uniforme que contribui significativamente para a distinguibilidade dos registos. Pode-se observar este comportamento na figura 3.1, 3.2 e 3.3.
- **Geography:** Quando combinado com o atributo *Age*, a distinção sobe significativamente (a combinação *Geography, Age* atinge 1.96% de distinção e 98.82% de separação). Pode-se observar isto na figura 3.2.
- **Gender:** Contribui de forma expressiva para o aumento da métrica de separação quando em combinação com a *Age*. Isto é observável nas figuras 3.2 e 3.3.
- **IsActiveMember:** As suas combinações com *Age* e *Geography* revelam uma distinção relevante para o risco de *linkage*. Pode ser observado na figura 3.3.

Quasi-identifier	Distinction	Separation
Tenure	0.11%	90.39774%
Age	0.7%	96.89822%
Age, Tenure	6.5%	99.70316%

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%
Age	0.7%	96.89822%
Geography, Age	1.96%	98.81936%

Quasi-identifier	Distinction	Separation
Gender	0.02%	49.58726%
Age	0.7%	96.89822%
Gender, Age	1.35%	98.42979%

FIGURA 3.1: Análise de distinção e separação individual.

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%

Quasi-identifier	Distinction	Separation
Gender	0.02%	49.58726%

Quasi-identifier	Distinction	Separation
Age	0.7%	96.89822%

Quasi-identifier	Distinction	Separation
Tenure	0.11%	90.39774%

Quasi-identifier	Distinction	Separation
IsActiveMember	0.02%	49.95939%

FIGURA 3.2: Análise de distinção e separação para pares de atributos.

Quasi-identifier	Distinction	Separation
Geography	0.03%	62.43544%
Tenure	0.11%	90.39774%
Age	0.7%	96.89822%
Geography, Tenure	0.33%	96.38668%
Geography, Age	1.96%	98.81936%
Age, Tenure	6.5%	99.70316%
Geography, Age, Tenure	15.95%	99.88705%

Quasi-identifier	Distinction	Separation
IsActiveMember	0.02%	49.95939%
Geography	0.03%	62.43544%
Age	0.7%	96.89822%
Geography, IsActiveMember	0.06%	81.19772%
Age, IsActiveMember	1.31%	98.44353%
Geography, Age	1.96%	98.81936%
Geography, Age, IsActiveMember	3.62%	99.40764%

FIGURA 3.3: Análise de distinção e separação para trios de atributos.

3.1.3 Atributos Sensíveis

Estes atributos contêm informação financeira confidencial, que poderiam comprometer um cliente caso este conseguisse ser re-identificado.

- **CreditScore:** Pontuação financeira pessoal e atributo central do objetivo analítico de divulgação. Contendo 460 valores únicos(permite uma proteção eficaz através da aplicação direta dos modelos *l*-diversity e *t*-closeness).
- **Balance:** Saldo bancário da conta. Trata-se de informação financeira crítica que os clientes desejam manter estritamente privada (possui cerca de 6382 valores únicos).
- **EstimatedSalary:** Salário anual estimado. Dado financeiro estritamente pessoal (apresenta cerca de 9999 valores únicos).

3.1.4 Atributos Insensíveis

Estes dados não representam um risco de re-identificação significativo nem contêm informação intrinsecamente confidencial, pelo que serão mantidos intactos:

- **HasCrCard:** Atributo binário que apresenta baixa distinção e separação, tanto individualmente como em combinação com outros atributos. Não se evidencia como um fator diferenciador, ao contrário de atributos como Gender e IsActiveMember, este não apresenta aumentos significativos de distinção ou separação quando combinado com outros atributos, justificando assim a sua classificação como insensível em vez de QID. Isto reduz o espaço de generalização necessário, melhorando a utilidade do dataset anonimizado.
- **NumOfProducts:** Possui apenas 4 valores únicos (1 a 4 produtos) e, de acordo com as métricas analisadas, não agrava o risco de privacidade de forma relevante.
- **Exited**: binário, baixa distinção

3.2 Riscos de Privacidade do Dataset Original

Os riscos de re-identificação inerentes ao *dataset* na sua forma original foram avaliados segundo três modelos de ataque padronizados:

- **Prosecutor**: Assume que o adversário tem como alvo um indivíduo específico e possui a informação prévia de que esse mesmo indivíduo se encontra na base de dados.
- **Journalist**: Assume que o atacante não tem um alvo predefinido, selecionando um indivíduo de forma aleatória. O objetivo principal deste ataque é demonstrar que a re-identificação de qualquer registo é possível.
- **Marketer**: O atacante visa atingir o maior número possível de indivíduos. O ataque é considerado bem-sucedido se for possível re-identificar uma proporção substancial da base de dados.

Os riscos de re-identificação estimados para os modelos citados encontram-se sumarizados na Tabela 3.1 e ilustrados na Figura 3.4.

Modelo de Ataque	Records at Risk	Highest Risk	Success Rate
Prosecutor	67.47%	100%	41.22%
Journalist	67.47%	100%	41.22%
Marketer	-	-	41.22%

TABELA 3.1: Análise dos riscos relativos a diferentes ataques

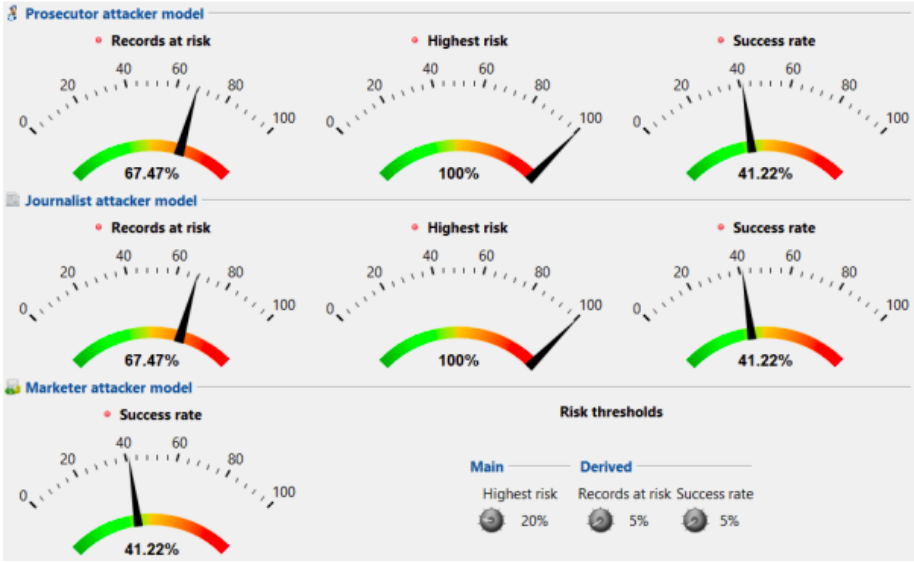

FIGURA 3.4: Riscos de re-identficação no modelo original.

3.3 Distribuição de Atributos

O estudo da distribuição dos atributos é importante, uma vez que a densidade e dispersão dos dados influenciam diretamente a construção de hierarquias de generalização eficientes. Uma boa análise permite criar hierarquias que evitem perdas drásticas de utilidade em zonas de elevada concentração de dados, prevenindo em simultâneo a criação de classes de equivalência isoladas (*outliers*).

Esta análise incidiu sobre os atributos contínuos ou com maior variabilidade (excluindo-se, por conseguinte, os atributos binários e a variável categórica *Geography*, que apresenta apenas três valores possíveis). Destacam-se as seguintes observações:

- **Age**: Apresenta uma distribuição assimétrica, com forte concentração de clientes na faixa etária entre os 25 e os 50 anos, exibindo uma cauda longa (*long tail*) que se estende até aos 92 anos. Esta concentração leva à necessidade de intervalos hierárquicos mais granulares nas idades centrais.

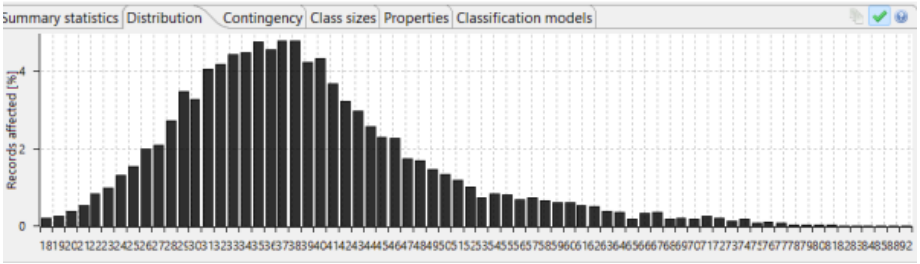

FIGURA 3.5: Distribuição de idades visto no *ARX*.

- **Tenure**: Revela uma distribuição aproximadamente uniforme ao longo do intervalo de 0 a 10 anos, registando-se apenas um ligeiro decréscimo nos extremos (0 e 10). Esta linearidade permitirá uma abordagem de generalização mais simétrica e regular.

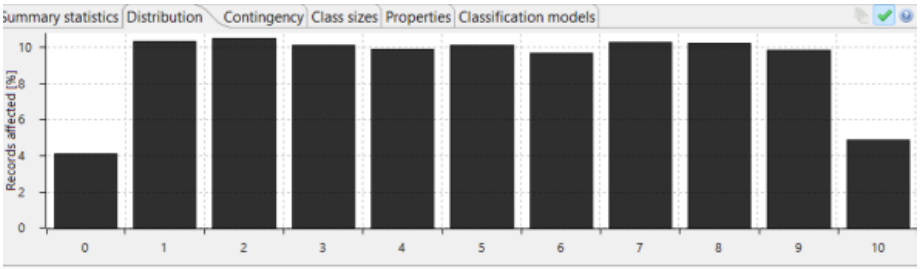

FIGURA 3.6: Distribuição de tenure visto no *ARX*.

3.4 Criação de Hierarquias

No seguimento da secção anterior foram desenhadas então várias hierarquias tendo em conta a distribuição de cada QID e o objetivo da divulgação.

3.4.1 Age

Visto que a idade apresentada uma distribuição assimétrica (referenciar 3.5), foi criada a seguinte hierarquia por intervalos:

Nível 0	Nível 1	Nível 2	Nível 3
18–92 (original)	[18,25[, [25,35[, [35,45[, [45,55[, [55,93[	[18,35[, [35,55[, [55,93[	[18,93[

TABELA 3.2: Hierarquias criadas para o atributo de idade

Os cortes do Nível 1 correspondem às faixas etárias utilizadas na estatística-alvo. O intervalo [18,25[é mais curto por conter menos registos; o intervalo [55,93[é mais amplo por agrupar a cauda longa da distribuição. Pode-se ver um exemplo na figura 3.7.

Level-0	Level-1	Level-2	Level-3
18	[18, 25[	[18, 35[	[18, 93[
19	[18, 25[	[18, 35[	[18, 93[
20	[18, 25[	[18, 35[	[18, 93[
21	[18, 25[	[18, 35[	[18, 93[
22	[18, 25[	[18, 35[	[18, 93[
23	[18, 25[	[18, 35[	[18, 93[
24	[18, 25[	[18, 35[	[18, 93[
25	[25, 35[	[18, 35[	[18, 93[
26	[25, 35[	[18, 35[	[18, 93[
27	[25, 35[	[18, 35[	[18, 93[
28	[25, 35[	[18, 35[	[18, 93[
29	[25, 35[	[18, 35[	[18, 93[
30	[25, 35[	[18, 35[	[18, 93[
31	[25, 35[	[18, 35[	[18, 93[
32	[25, 35[	[18, 35[	[18, 93[
33	[25, 35[	[18, 35[	[18, 93[
34	[25, 35[	[18, 35[	[18, 93[

FIGURA 3.7: Amostra das hierarquias para idade criadas no *ARX*.

3.4.2 Tenure

Visto que o atributo *Tenure* apresentada uma distribuição mais simétrica (referenciar 3.6), foi criada a seguinte hierarquia por intervalos:

Nível 0	**Nível 1**	**Nível 2**	**Nível 3**
0–10 (original)	[0,3[, [3,6[, [6,9[, [9,12[	[0,6[, [6,12[	[0,12[

TABELA 3.3: Hierarquias criadas para o atributo de tenure

É possível ver também na figura 3.8 a distrubuição por hierarquias no ARX.

Level-0	Level-1	Level-2	Level-3
0	[0, 3[	[0, 6[	[0, 12[
1	[0, 3[	[0, 6[	[0, 12[
2	[0, 3[	[0, 6[	[0, 12[
3	[3, 6[	[0, 6[	[0, 12[
4	[3, 6[	[0, 6[	[0, 12[
5	[3, 6[	[0, 6[	[0, 12[
6	[6, 9[	[6, 12[	[0, 12[
7	[6, 9[	[6, 12[	[0, 12[
8	[6, 9[	[6, 12[	[0, 12[
9	[9, 12[	[6, 12[	[0, 12[
10	[9, 12[	[6, 12[	[0, 12[

FIGURA 3.8: Amostra das hierarquias para tenure criadas no *ARX*.

3.4.3 Geography

Para a geografia criou-se a seguinte hierarquia categórica, baseada na secção geográfica das localizações.

Nível 0	**Nível 1**	**Nível 2**
France	Western Europe	Europe
Germany	Western Europe	Europe
Spain	Southern Europe	Europe

TABELA 3.4: Hierarquias criadas para o atributo *Geography*

3.4.4 Gender e IsActiveMember

Sendo estes atributos binários existe apenas um nível de generalização possível.

Nível 0	**Nível 1**
0/1	*
F/M	*

TABELA 3.5: Hierarquias criadas para o atributos *Gender* e *IsActiveMember*

3.5 Peso dos Atributos

Por fim, dado o objetivo de divulgação (CreditScore médio por faixa etária), atribui-se **peso 1.0** ao atributo **Age**. Novamente, esta decisão visa minimizar a perda de informação neste atributo durante a anonimização, uma vez que é o QID com maior impacto na utilidade da estatística-alvo. Os restantes QIDs mantêm o peso por defeito (0.5). Podemos ver esta configuração no ARX na figura 3.9.

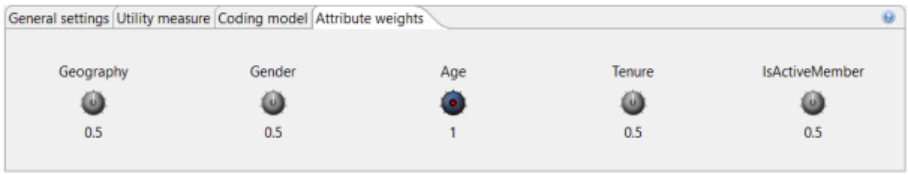

FIGURA 3.9: Configuração dos pesos no *ARX*.

Capítulo 4

Modelos de Privacidade: Utilidade, Privacidade e Avaliação de Risco

4.1 k-Anonymity e l-Diversity

O primeiro modelo a ser aplicado foi a combinação de **k-Anonymity** com **l-Diversity**. O princípio de *k-anonymity* estipula que os Quase-Identificadores (QIDs) de um determinado indivíduo devem ser indistinguíveis dos de, pelo menos, $k - 1$ outros indivíduos no *dataset*. Para atingir este objetivo, o algoritmo recorre a técnicas de generalização e supressão para criar **classes de equivalência** de tamanho mínimo k.

Contudo, este modelo por si só pode deixar lacunas de privacidade (como ataques de homogeneidade) se não existir diversidade suficiente nos **atributos sensíveis** dentro dessas mesmas classes. É aqui que intervém o *l-diversity*, uma extensão que garante que existam, pelo menos, l valores distintos para os atributos sensíveis dentro de cada classe de equivalência, prevenindo assim a dedução direta de informação confidencial.

4.2 Aplicação do Modelo 1

Neste caso prático, o atributo sensível principal protegido pelo modelo l-diversity é o **CreditScore** (que contém 460 valores únicos), sendo este complementado pelos atributos **Balance** e **EstimatedSalary**.

4.2.1 Exploração e Escolha do Parâmetro K

Iniciou-se a análise mantendo o parâmetro l fixo ($l = 2$ para todos os atributos sensíveis) e variando o parâmetro k entre os valores 5, 10, 15 e 18. Para avaliar o impacto destas variações, consideraram-se as seguintes métricas:

- **Highest Risk e Success Rate** (privacidade)
- **Loss Score** (utilidade principal)
- **N.-U. Entropy** (semelhança das distribuições)
- **Discernibility** (tamanho das classes de equivalência)
- **Record-level e Attribute-level Squared Error** (qualidade dos dados)
- **Suppressed Records** (percentagem de supressão)

A Tabela 4.1 resume as transformações ótimas encontradas pelo *ARX* para cada valor de k testado:

k	Transformação ótima	Generalização de Age
5	[0, 0, 2, 0, 0]	Nível 2 - 3 faixas: [18,35[, [35,55[, [55,93
10	[0, 0, 1, 1, 0]	Nível 1 - 5 faixas: [18,25[, [25,35[, [35,45[, [45,55[, [55,93[
15	[1, 0, 1, 1, 0]	Nível 1 - 5 faixas (Geography generalizado ao nível 1)
18	[0, 0, 3, 1, 0]	Nível 3 - 1 faixa: [18,93[(toda a informação de Age perdida)

TABELA 4.1: Transformações ótimas por valor de k (ordem: Geography, Gender, Age, Tenure,IsActiveMember)..

A Tabela 4.2 apresenta os resultados das métricas de utilidade e privacidade para os diferentes valores de k testados. Desde logo, destaca-se o resultado obtido para $k = 18$, que pode ser considerado ilusório à primeira vista.

Embora este cenário apresente 0.00% de registos suprimidos e o menor risco de reidentificação (apenas 1.61% de *Highest Risk*), este nível de proteção foi alcançado à custa da destruição da utilidade do atributo *Age*. Como a métrica de *Loss* avalia a perda de granularidade e de detalhe da informação original, a presença do valor `0.00` indica uma anomalia na preservação dos dados: o algoritmo foi forçado a generalizar a idade para o seu nível máximo (uma única faixa abrangendo todos os clientes, dos 18 aos 93 anos) para conseguir cumprir o requisito de formar grupos de 18 indivíduos sem violar o limite de 3% de supressão.

Esta generalização extrema elimina por completo a variabilidade do atributo *Age*, **inviabilizando o objetivo analítico** estipulado de estudar a relação entre as diferentes faixas etárias e o *Credit Score*.

Métrica	**k=5**	**k=10**	**k=15**	**k=18**
Loss Score (%)	1.55	2.74	2.79	0.00*
N.-U. Entropy (%)	66.47	59.33	53.79	44.58
Discernibility (%)	98.11	96.59	96.05	97.51
Record-level Squared Error (%)	78.19	82.56	75.82	23.73
Attribute-level Squared Error (%)	91.04	92.86	92.62	1.97
Highest Risk (%)	20.00	10.00	6.25	1.61
Success Rate (%)	3.40	2.01	1.30	0.48
Suppressed Records (%)	1.52	2.69	2.74	0.00

TABELA 4.2: Métricas de utilidade e privacidade por valor de *k*.

4.2.1.1 Análise dos resultados e Escolha de K

Analisando a transição de $k = 5$ para $k = 10$, observa-se uma descida significativa do risco máximo (*Highest Risk*) de **20% para 10%,** acompanhada por um aumento moderado do *Loss Score* (de 1.55% para 2.74%). Adicionalmente, a transformação ótima para $k = 10$ **generaliza o atributo *Age* apenas ao Nível 1** (5 faixas etárias), enquanto a configuração inferior falhava neste equilíbrio. O atributo *Tenure* é também generalizado ao Nível 1.

Contudo, ao progredir de $k = 10$ para $k = 15$, constata-se que o *Loss Score* **permanece praticamente inalterado** (aumentando apenas de 2.74% para 2.79%), enquanto o *Highest Risk* **sofre uma redução considerável (de 10% para 6.25%)**. O custo associado a esta melhoria na privacidade é a generalização do atributo *Geography* ao Nível 1 (agrupando em *Western Europe / Southern Europe*). Os atributos *Age* e *Tenure* mantêm-se no Nível 1, preservando as 5 faixas etárias estritamente necessárias para a análise analítica delineada.

Por outro lado, testando valores como $k = 18$ (ou superiores), elimina-se por completo a utilidade do atributo *Age*, inviabilizando a capacidade de relacionar e calcular o *CreditScore* médio por faixa etária, como previamente mencionado.

Em suma, conclui-se que $k = 15$ **representa o *trade-off* ideal** entre privacidade e utilidade para o objetivo deste projeto. Esta configuração oferece riscos de reidentificação mais aceitáveis (*Highest Risk* de 6.25%, *Success Rate* de 1.30%), mantém a percentagem de

supressão estritamente dentro do limite estipulado (2.74% $<$ 3%) e preserva o atributo *Age* no melhor nível de granularidade para garantir o sucesso da análise proposta.

4.2.2 Exploração e Escolha do Parâmetro L

Tendo fixado o valor ótimo de $k = 15$, procedeu-se à exploração do parâmetro l para o atributo sensível principal (*CreditScore*), mantendo a restrição de $l = 2$ para os atributos secundários (*Balance* e *EstimatedSalary*). Foram testados os valores $l = 2$, $l = 3$ e $l = 5$ para o *CreditScore*.

Observou-se que, para todos os valores testados, a transformação ótima, as métricas de utilidade e os riscos de reidentificação mantiveram-se inalterados, ou seja, apresentaram exatamente os mesmos resultados obtidos para a configuração base de $l = 2$.

Acreditamos que este comportamento se deve à elevada cardinalidade do atributo *CreditScore* (que possui 460 valores únicos) e ao facto do tamanho mínimo das classes de equivalência imposto pelo *k-anonymity*, onde cada classe contém, no mínimo, 15 registos.

Neste cenário, cada classe de equivalência gerada contém naturalmente uma grande diversidade de valores de *CreditScore*, satisfazendo a condição do *l-diversity* sem que o algoritmo necessite de "forçar"qualquer generalização ou supressão adicional, mesmo quando se exigem valores de l relativamente elevados.

Esta observação permite concluir que, para a configuração deste *dataset* e para este atributo específico, a restrição ativa que determina o nível de anonimização é o valor de k, e não o valor de l. A imposição de $k = 15$, por si só, já garante diversidade suficiente nos atributos sensíveis de alta variabilidade.

4.2.3 Resultados do Modelo 1

Portanto, a configuração final do modelo 1, é k=15, l=2 para CreditScore, Balance e EstimatedSalary, com a transformação [1, 0, 1, 1, 0] pode ser observado na tabela 4.3. As métricas podem novamente ser vistas na tabela 4.2.

Atributo	Nível de Generalização	Resultado
Geography	1	Western Europe / Southern Europe
Gender	0	Sem generalização
Age	1	[18,25[, [25,35[, [35,45[, [45,55[, [55,93[
Tenure	1	[0,3[, [3,6[, [6,9[, [9,12[
IsActiveMember	0	Sem generalização

TABELA 4.3: Níveis de generalização aplicados aos QIDs na configuração ótima selecionada para o primeiro modelo.

4.2.3.1 Riscos de Re-identificação Após Modelo 1

Após a aplicação do modelo 1, pode-se observar que os riscos de re-identificação baixaram drásticamente na figura 4.1 para os 3 tipos de ataque anteriormente identificados.

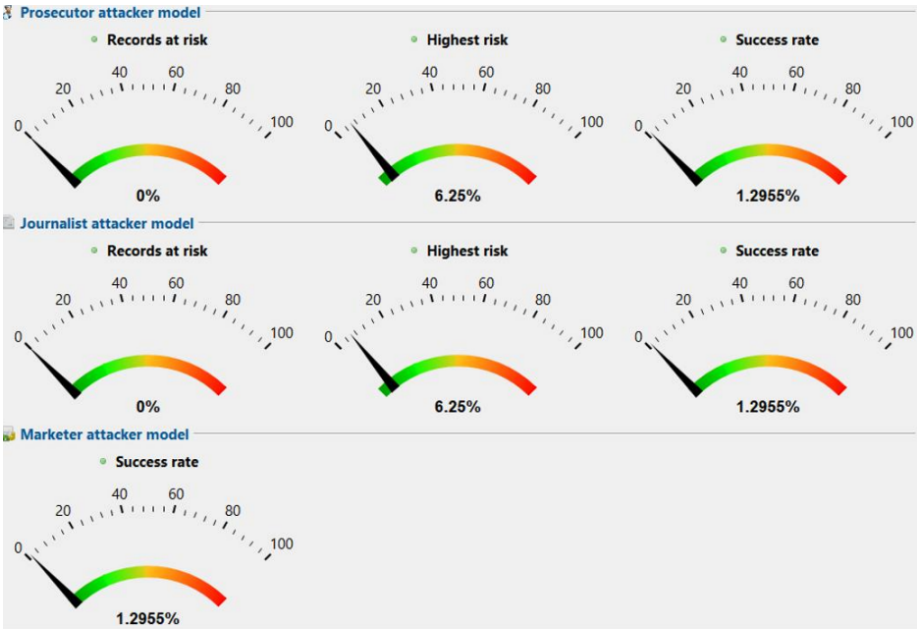

FIGURA 4.1: Riscos de re-identifcação após aplicar modelo 1.

4.2.3.2 Análise dos Resultados

Como se pode constatar pela Tabela 4.4, o processo de anonimização cumpriu eximiamente o objetivo analítico proposto. Nas faixas centrais ([25, 35[e [35, 45[), onde se concentra a esmagadora maioria dos clientes, a diferença no CreditScore médio foi nula (0.00).

Os desvios residuais observados nas faixas dos extremos explicam-se pelos 2.74% de registos suprimidos (principalmente *outliers*), demonstrando que a utilidade do *dataset* para o departamento de risco foi preservada.

Faixa Etária	***CreditScore* Original**	***CreditScore* Anonimizado**	**Diferença**
[18, 25[	653.97	656.21	+2.24
[25, 35[	651.33	651.33	0.00
[35, 45[	650.87	650.87	0.00
[45, 55[	645.79	645.91	+0.12
[55, 93[	652.11	650.76	-1.35

TABELA 4.4: Comparação do *CreditScore* médio entre o *dataset* original e o anonimizado, por faixa etária no primeiro dataset anonimizado.

4.3 k-Anonymity e t-Closeness

O modelo *t*-closeness estende o nível de proteção do *k*-anonymity ao exigir que a **distribuição de um atributo sensível dentro de qualquer classe de equivalência seja estritamente "próxima"da distribuição desse mesmo atributo em todo o *dataset* original**.

O modelo aplicado na secção anterior foca-se em garantir diversidade (valores distintos), contudo, ignora a **semântica e a magnitude** dessas diferenças. Por exemplo, uma classe de equivalência pode conter clientes com três salários distintos (garantindo $l = 3$), mas se esses valores forem 25.000€, 26.000€ e 27.000€, um atacante pode inferir com elevada confiança que qualquer indivíduo pertencente a essa classe tem um salário relativamente baixo face à média do banco. (Consultar anexo A para rever as distribuições de salários).

Para colmatar esta vulnerabilidade e evitar inferências sobre a vizinhança dos valores, o *t*-closeness impõe um limite máximo (designado por *t*) para a discrepância entre a distribuição local da classe e a distribuição global do *dataset*. Sendo o *CreditScore*, o *EstimatedSalary* e o *Balance* atributos numéricos contínuos, esta distância é quantificada através da métrica **Earth Mover's Distance** que calcula o custo ou "esforço"necessário para transformar a forma de uma distribuição na outra, garantindo que os grupos anonimizados refletem a diversidade dos dados originais.

4.4 Aplicação do Modelo 2

Numa primeira fase exploratória, testaram-se diversas configurações aplicando o modelo *t-closeness* (*ordered-distance*) simultaneamente aos três atributos classificados como sensíveis (*CreditScore*, *Balance* e *EstimatedSalary*). Para esta avaliação, estipulou-se inicialmente o mesmo limiar t para os três atributos, variando os valores testados entre 0.10 e 0.30, conjugados com níveis de k entre 5 e 20.

A Tabela 4.5 apresenta a análise inicial destas iterações.

k	t	Melhor Transformação	Max Score
5	0.15	[0, 0, 1, 3, 0]	25,12%
5	0.20	[0, 0, 1, 3, 0]	3,20%
10	0.15	[0, 0, 1, 3, 0]	25,12%
10	0.20	[0, 0, 1, 3, 0]	3,20%
15	0.15	[0, 0, 1, 3, 0]	25,12%

TABELA 4.5: Resultados da aplicação preliminar de t-closeness a todos os atributos sensíveis em simultâneo.

4.4.1 Resultados do Modelo 2

Uma observação interessante desta análise inicial foi constatar que o limiar $t = 0.20$ atuava como *bottleneck*. A exigência deste valor no atributo de Balance impedia melhorias na privacidade global do modelo. Desta forma, procedeu-se a uma otimização iterativa (*fine-tuning*), ajustando o valor de t de forma individualizada para cada atributo sensível. O objetivo central desta abordagem foi maximizar o nível de proteção k, minimizando simultaneamente a distância distributiva (t) possível para cada variável financeira, sem comprometer a utilidade da idade.

A configuração ótima alcançada encontra-se descrita na Tabela 4.6. A supressão ficou na ordem dos 3.15%.

Transformação	k	*t-Balance*	*t-Credit*	*t-Salary*	*Loss Score*
[0, 0, 1, 3, 0]	18	0.20	0.09	0.08	3.20%

TABELA 4.6: Resultado final ótimo da aplicação individualizada do *t-closeness*.

Portanto, os níveis de generalização finais aplicados ao *dataset* podem ser observados na Tabela 4.7. É de salientar que esta estratégia permitiu conservar o atributo *Age* no

seu nível mínimo de generalização exigido (5 faixas etárias), garantindo a viabilidade do objetivo de divulgação. O *trade-off* necessário para atingir este elevado nível de privacidade ($k = 18$) incidiu, como planeado estrategicamente, na supressão total da utilidade do atributo secundário *Tenure*.

Atributo	**Nível de Generalização**	**Resultado**
Geography	0	Sem generalização
Gender	0	Sem generalização
Age	1	[18,25[, [25,35[, [35,45[, [45,55[, [55,93[
Tenure	3	[0,12[(Generalização Máxima)
IsActiveMember	0	Sem generalização

TABELA 4.7: Níveis de generalização aplicados aos Quase-Identificadores na configuração ótima do Modelo 2.

4.4.1.1 Riscos de Re-identificação Após Modelo 2

Após a aplicação do segundo modelo, é possível observar na figura 4.2, que os resultados foram ligeiramente superiores aos do primeiro modelo, ainda que, à custa, de uma maior supressão de informação (embora menos de 0.5%).

FIGURA 4.2: Riscos de re-identifcação após aplicar modelo 2.

4.4.1.2 Análise dos Resultados

Como se pode observar na table 4.8, o processo de anonimização também cumpriu o objetivo analítico proposto, conseguindo ainda superar o primeiro modelo.

Faixa Etária	***CreditScore* Original**	***CreditScore* Anonimizado**	**Diferença**
[18, 25[	653.97	656.21	-0.19
[25, 35[	651.33	651.33	-0.17
[35, 45[	650.87	650.87	0.00
[45, 55[	645.79	645.91	0.00
[55, 93[	652.11	650.76	0.58

TABELA 4.8: Comparação do *CreditScore* médio entre o *dataset* original e o anonimizado, por faixa etária no segundo dataset anonimizado.

Capítulo 5

Reflexões finais e Conclusão

5.1 Comparação dos Modelos

A aplicação iterativa de diferentes modelos de privacidade permitiu isolar duas configurações candidatas viáveis para a divulgação segura dos dados.

O **Modelo 1** ($k = 15$, $l = 2$) demonstrou uma preservação ligeiramente superior da utilidade global estrutural, conseguindo manter o atributo secundário *Tenure* no Nível 1 de generalização. Pelo contrário, o **Modelo 2** ($k = 18$, *t-closeness*) exigiu um sacrifício maior, forçando a generalização do *Tenure* ao seu nível máximo para conseguir convergir.

No entanto, a **avaliação de um processo de anonimização deve ser ponderada em função do seu objetivo principal de divulgação**. Ao avaliar o requisito central estipulado: **a preservação do *CreditScore* médio por faixa etária**, o **Modelo 2** é superior. Como demonstrado nas análises anteriores, o desvio máximo gerado pelo Modelo 2 nas faixas etárias foi inferior ao do Modelo 1, garantindo uma maior fidelidade estatística.

Adicionalmente, sob o ponto de vista estrito da cibersegurança, o *t-closeness* oferece garantias contra ataques de distorção (*skewness attacks*) e inferência de proximidade em variáveis financeiras críticas (*Balance* e *Salary*), um vetor de ameaça que o *l-diversity* não mitiga por completo.

Portanto, **recomendamos a adoção e publicação do *dataset* gerado pelo Modelo 2**, assumindo a perda do *Tenure* como um *trade-off* necessário e aceitável em prol de uma proteção financeira robusta e de uma análise de risco de crédito fiável.

5.2 Recomendações de Consultoria

Atuando como um serviço profissional de consultoria, e refletindo todo o conhecimento técnico e analítico retirado deste projeto, delineiam-se as seguintes recomendações para a instituição em futuros processos de libertação de dados:

1. **Objetivo de Divulgação:** O processo de anonimização deve ser sempre guiado pelo propósito final do *dataset*. Ao identificar claramente a relação analítica central logo à partida (neste caso, a correlação entre *Age* e *CreditScore*), torna-se possível calibrar os pesos dos atributos de forma adequada. Ao atribuir maior peso aos atributos vitais para a análise, orienta-se o algoritmo para concentrar as perdas e generalizações estritamente nas variáveis secundárias.

2. **Quase-Identificadores (QIDs):** Recomendamos uma análise individual e combinada a cada atributo, evitando classificações precipitadas. Atributos que aparentam ser "inocentes"ou insensíveis num cenário isolado podem facilmente revelar-se QIDs perigosos em diferentes contextos. A avaliação empírica de métricas como a distinção e a separação é fundamental, pois combinações de dados inofensivos abrem frequentemente portas a ataques de cruzamento de informação (*linkage*).

3. **Iteração Contínua e Compreensão dos Dados:** A maximização do potencial analítico de um *dataset* exige tempo, paciência e iteração contínua. Não é um procedimento automático. Para alcançar a otimização ideal, é imperativo que a equipa compreenda profundamente a distribuição estatística subjacente a cada variável antes de aplicar os modelos de privacidade, para perceber como é que a manipulação de parâmetros altera o comportamento dos dados.

5.3 Conclusão

Este projeto demonstrou que a anonimização de dados exige um equilíbrio rigoroso entre a mitigação do risco e a preservação da utilidade analítica. A solução final adotada (Modelo 2, com $k = 18$ e *t-closeness* otimizado) reduziu os riscos de reidentificação e de inferência semântica a níveis residuais. Em simultâneo, o modelo cumpriu com sucesso o objetivo principal: preservar a relação estatística entre as faixas etárias e o *CreditScore*. Conclui-se assim que objetivos traçados para o projeto foram cumpridos e o *dataset* resultante poderia ser libertado ao público geral, sem sérias consequências.

Apêndice A

Anexos

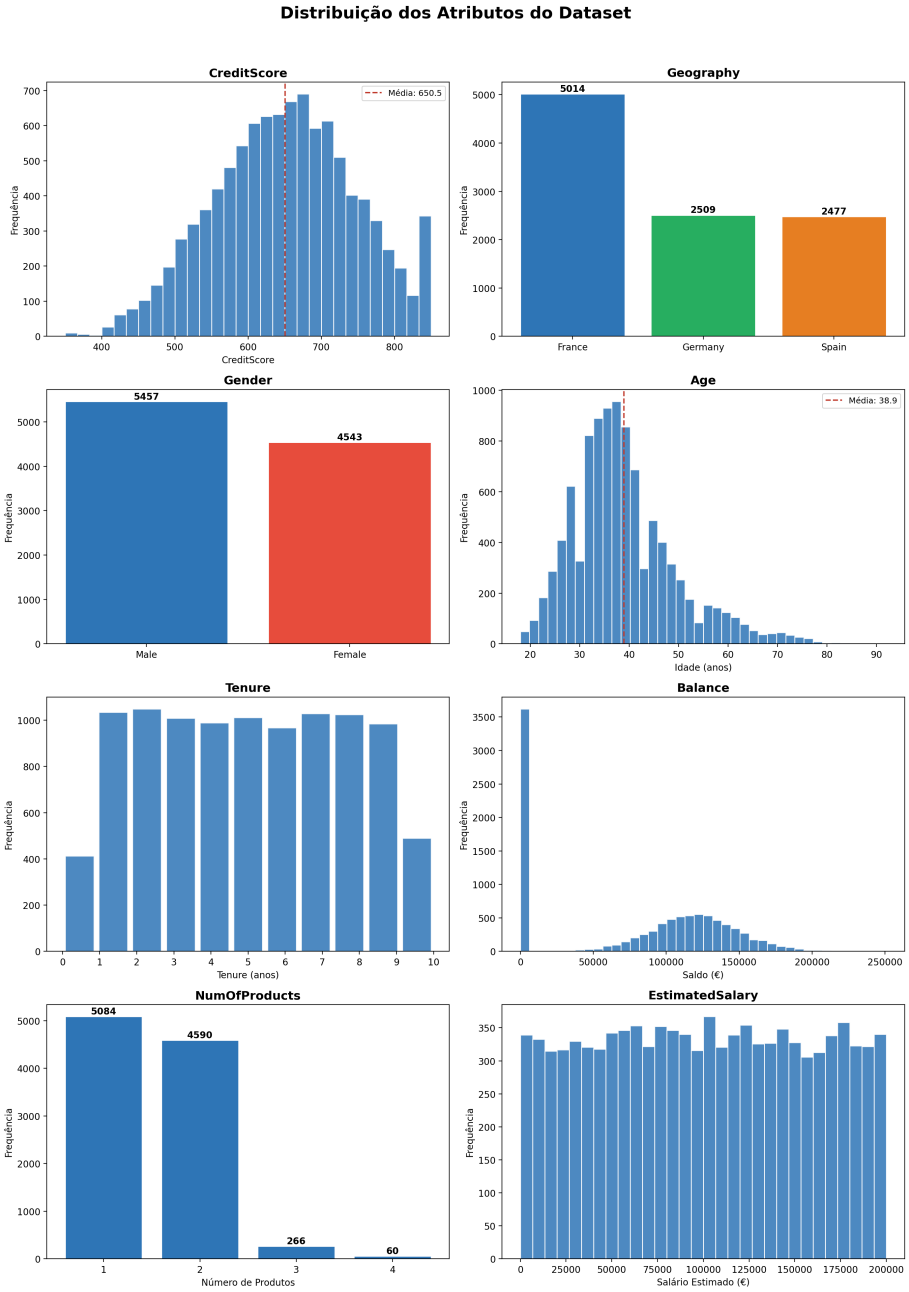

FIGURA A.1: Distribuição do Dataset

Bibliografia